

RF-DETR

Busca de arquitetura neural para detecção em tempo real
Robinson et al. (2025)

AGENDA

Problema e arquitetura

Backbone e ablações


NAS e arquiteturas descobertas

Treinamento e métricas

Resultados e conclusões

O PROBLEMA: PRECISÃO OU VELOCIDADE?

- Modelos de vocabulário aberto têm boa transferência, mas são pesados e lentos.
- Detectores especializados são rápidos, porém podem ficar excessivamente ajustados ao COCO.
- O desafio é combinar precisão, latência e generalização.



A PROPOSTA DO RF-DETR

O modelo moderniza o LW-DETR e combina três ideias:

- Conhecimento visual do DINOv2;
- Detecção end-to-end sem NMS;
- NAS para escolher o melhor ponto entre precisão e latência.

Uma única super-rede origina várias configurações.


TRÊS CONTRIBUIÇÕES CENTRAIS



Detecção e segmentação em tempo real

ARQUITETURA: DO PIXEL À PREDIÇÃO

- O DINOv2 extrai características visuais robustas.
- O projetor produz mapas em múltiplas escalas.
- Atenção global e por janelas equilibram contexto e custo.
- Queries e decoder produzem classes, caixas e, opcionalmente, máscaras.



POR QUE TROCAR CAEV2 POR DINOv2?

O RF-DETR substitui o CAEv2 do LW-DETR pelo DINOv2.

O pré-treinamento em grande escala fornece características mais robustas, sobretudo em bases pequenas.

Na ablação, o DINOv2-S obteve o maior AP com latência próxima à do CAEv2.

Backbone	Params · GFLOPs · ms · AP
CAEv2 S-16	28,3M · 83,7 · 4,4 · 52,3
DINOv2-S/14	32,3M · 78,2 · 4,7 · 54,3
SigLIPv2-B/32	105,1M · 81,6 · 4,8 · 50,4
SAM2 Hiera-S	44,0M · 109,1 · 11,2 · 53,6
Ganho vs. CAEv2	+2,0 AP
Escolha final	DINOv2: melhor AP

COMO O LW-DETR EVOLUIU PARA O RF-DETR

A ablação separa o efeito de cada decisão técnica.

Os hiperparâmetros mais suaves reduzem inicialmente o AP, mas ajudam a preservar o conhecimento do DINOv2.

Com DINOv2, pré-treino adicional e NAS, o modelo chega a 54,6 AP.


Etapa	Params · GFLOPs · ms · AP
LW-DETR M	28,2M · 83,7 · 4,4 · 52,6
+ Hiperparâmetros suaves	28,2M · 83,7 · 4,4 · 51,6
+ DINOv2	32,3M · 78,2 · 4,7 · 53,6
+ Pré-treino O365	32,3M · 78,2 · 4,7 · 54,3
+ NAS compartilhada	32,3M · 78,2 · 4,7 · 54,6
Ganho final	+2,0 AP vs. LW-DETR

NAS COM PESOS COMPARTILHADOS

Em cada iteração:

1. Uma configuração é amostrada;
2. A sub-rede realiza a predição;
3. A perda é calculada;
4. Os pesos compartilhados são atualizados.

Depois, a busca seleciona as configurações na fronteira de Pareto.



CINCO CONTROLES DEFINEM O MODELO FINAL

Cada controle altera o equilíbrio entre velocidade e precisão:

- Mais resolução e patches menores preservam detalhes;
- Mais camadas refinam as previsões;
- Mais queries permitem detectar mais objetos;
- Mais contexto de atenção aumenta o custo.

A NAS escolhe o ponto adequado ao hardware.

01	Resolução	detalhe × custo
02	Patch	tokens × detalhe
03	Decoder	0 a 6 camadas
04	Queries	limite de objetos
05	Janelas	contexto × latência

CONFIGURAÇÕES ENCONTRADAS PELA NAS

Cada tamanho corresponde a uma configuração Pareto-ótima.

A resolução e o número de camadas crescem conforme aumenta o orçamento de latência.

Os modelos maiores também passam do DINOv2-S para o DINOv2-B.

Modelo	Res · P · J · Dec · Q · Backbone
Nano	384 · 16 · 2 · 2 · 300 · DINOv2-S
Small	512 · 16 · 2 · 3 · 300 · DINOv2-S
Medium	576 · 16 · 2 · 4 · 300 · DINOv2-S
Large	704 · 16 · 2 · 4 · 300 · DINOv2-S
2XL	880 · 20 · 2 · 5 · 300 · DINOv2-B
Padrão	Mais latência → resolução + profundidade

O QUE A NAS DESCOBRIU

A busca revelou estratégias diferentes para detecção e segmentação.

Na detecção, as 300 queries são mantidas e a profundidade cresce.

Na segmentação, queries e camadas aumentam juntas.

O melhor escalonamento depende da tarefa.

01	Detecção	decoder largo e raso
02	Segmentação	decoder fino e profundo
03	Patch	16 no S · 20 no B
04	Máscaras	patch 12 · Q 100→300
05	Janelas	2 geralmente é o ideal

TREINAMENTO E HIPERPARÂMETROS

O artigo informa 60 épocas de pré-treinamento no Objects-365.

A taxa menor, o decaimento por camada e o gradient clipping reduzem alterações bruscas no backbone.

Nos conjuntos-alvo, o treinamento segue até a convergência; bases pequenas podem exigir mais de 100 épocas.

Hiperparâmetro	Valor
Pré-treino O365	60 épocas
Batch size	128
Learning rate	1×10^{-4}
Gradient clipping	0,1
Dcaimento/camada	0,8
Warm-up	Não

COMO O ARTIGO MEDE DESEMPENHO

A métrica principal é $AP_{50:95}$, média da precisão em vários limiares de IoU.

O artigo também separa objetos pequenos, médios e grandes.

Para eficiência, mede parâmetros, GFLOPs e latência.

A latência usa NVIDIA T4, TensorRT 10.4, pausa de 200 ms e o mesmo artefato para precisão e velocidade.

01	$AP_{50:95}$	métrica principal
02	AP_{50} / AP_{75}	IoU flexível × rigoroso
03	$AP_S / M / L$	porte dos objetos
04	GFLOPs + params	custo do modelo
05	Latência	T4 · TensorRT · 200 ms

RESULTADOS DE DETECÇÃO NO COCO

A família aumenta a precisão conforme cresce o orçamento de latência.

O Nano alcança 48,0 AP em 2,3 ms e supera o D-FINE Nano em 5,3 AP.

O 2XL chega a 60,1 AP e é apresentado como o primeiro detector em tempo real acima de 60 AP no COCO.

Modelo	Params · GFLOPs · ms · AP
RF-DETR Nano	30,5M · 31,9 · 2,3 · 48,0
RF-DETR Small	32,1M · 59,8 · 3,5 · 52,9
RF-DETR Medium	33,7M · 78,8 · 4,4 · 54,7
RF-DETR 2XL	126,9M · 438,4 · 17,2 · 60,1
D-FINE Nano	3,8M · 7,3 · 2,1 · 42,7
Ganho do Nano	+5,3 AP

RESULTADOS DE SEGMENTAÇÃO NO COCO

O RF-DETR-Seg mantém a detecção ponta a ponta e acrescenta máscaras por instância.

O Nano atinge 40,3 AP em 3,4 ms.

Mesmo o Nano supera o YOLOv11-Seg Medium em AP, com aproximadamente metade da latência.

Modelo	Params · GFLOPs · ms · AP
RF-DETR-Seg N	33,6M · 50,0 · 3,4 · 40,3
RF-DETR-Seg S	33,7M · 70,6 · 4,4 · 43,1
RF-DETR-Seg M	35,7M · 102,0 · 5,9 · 45,3
RF-DETR-Seg 2XL	38,6M · 435,3 · 21,8 · 49,9
YOLOv11-Seg M	22,4M · 123,3 · 6,9 · 38,5
Nano vs YOLO-M	+1,8 AP · ~2× mais rápido

A VANTAGEM CONTINUA FORA DO COCO

RF100-VL reúne 100 conjuntos de dados e mede melhor a transferência para aplicações reais.

RF100-VL

O RF-DETR 2XL ajustado alcança 63,5 AP, acima do GroundingDINO Tiny, e executa aproximadamente 20 vezes mais rápido.

63,5 AP 15,6 ms

RF-DETR 2XL ajustado

Na segmentação COCO, o RF-DETR-Seg Nano chega a 40,3 AP em 3,4 ms.

SEGMENTAÇÃO COCO

40,3 AP • 3,4 ms

CONCLUSÕES E LIMITAÇÕES

Principais limitações:

- A busca completa exige alto custo computacional;
- A latência depende do artefato e do protocolo de medição;
- O número de épocas nos conjuntos-alvo não é sempre explicitado;
- O ajuste fino pode reduzir a regularização e causar sobreajuste.

TAKEAWAY

DINOv2 + DETR + NAS

Precisão, velocidade e flexibilidade
sem retreinar cada variante

OBRIGADO A TODOS!

Dúvidas??

GITHUB



FORMS



inatel.tecnologias 
inatel.tecnologias 
inateloficial 
company/inatel 
www.inatel.br 

Campus em Santa Rita do Sapucaí
Minas Gerais - Brasil
Av. João de Camargo, 510
Centro - 37536-001

- RF-DETR
- Dúvidas?

Inatel



_o futuro
não tem hora,
mas tem lugar.