

REPViT: REVISITANDO CNNs MÓVEIS

Uma análise do artigo sob a perspectiva dos Vision Transformers

AGENDA

- 01 Motivação e questão de pesquisa
- 02 Construção incremental do RepViT
- 03 Avaliação experimental
- 04 Resultados em tarefas de visão
- 05 Pontos fortes, limitações e conclusão

POR QUE MODELOS MÓVEIS IMPORTAM

MOTIVAÇÃO

EDGE

Celulares, veículos e sistemas embarcados exigem respostas rápidas com memória e energia limitadas.

ViTs LEVES

Já entregavam bons resultados de acurácia e latência em dispositivos móveis.

VANTAGEM DAS CNNs

Convoluções possuem excelente suporte em bibliotecas e hardware móvel.




Figure 1. Comparison of latency and accuracy between RepViT (Ours) and others. The top-1 accuracy is tested on ImageNet-1K and the latency is measured by iPhone 12 with iOS 16. RepViT achieves the best trade-off between performance and latency.

O DESAFIO

**Alta
acurácia
+
baixa
latência**

no hardware real

“Princípios arquiteturais dos ViTs leves podem melhorar uma CNN leve pura?”

CNNs LEVES

- Operações convolucionais bem otimizadas
- Baixa complexidade espacial
- Bloco invertido tradicional

ViTs LEVES

- Estrutura MetaFormer recorrente
- Separação token/channel mixer
- Macro e microdesign mais recentes

HIPÓTESE

- O ganho não vem só da atenção
- Parte do desempenho vem do arranjo arquitetural
- Aplicar esse desenho em uma CNN pura

O foco do trabalho é comparar arquitetura, e não apenas “CNN vs Transformer”.

FLOPs ≠ LATÊNCIA REAL

Dois modelos com custo teórico parecido podem ter tempos muito diferentes no dispositivo.

**Métrica principal do artigo:
tempo medido no
hardware.**

iPhone 12

Dispositivo de teste

iOS 16 + Core ML Tools

Batch 1

Inferência

medição por imagem

224×224

ImageNet-1K

treino e teste

TREINAMENTO

300 ou 450 épocas seguindo a receita dos ViTs leves: AdamW, cosine schedule e data augmentation.

BASELINE


MobileNetV3-L mede 1,01 ms antes das modernizações.

POR QUE ISSO IMPORTA?

O objetivo é otimizar a arquitetura para o comportamento que realmente aparece no dispositivo — não só para uma métrica teórica.

COMO O REPViT FOI CONSTRUÍDO

Ponto de partida: MobileNetV3-L → modernização incremental → RepViT






Figure 3. **Block design.** (a) is a MobileNetV3 block with an optional squeeze-and-excitation (SE) layer. (b) is the designed RepViT block, which separates the token mixer and channel mixer through the structural re-parameterization technique. The SE layer is also optional in RepViT block. The norm layer and nonlinearity are omitted for simplicity.

TOKEN MIXER

Convolução depthwise 3×3 mistura informação espacial local.

CHANNEL MIXER


Convoluções 1×1 fazem a mistura entre os canais.

ESTRUTURA METAFomer

Os dois mixers passam a ficar separados, mas o modelo continua 100% convolucional.

SE permanece associado à informação espacial.

Reparametrização estrutural



TREINO

Múltiplos ramos facilitam a aprendizagem

INFERÊNCIA

Os ramos são fundidos em uma única convolução equivalente

Expansion ratio

6 → 2

Expansão interna

menos custo no channel mixer

48 • 96 • 192 • 384

Canais por estágio

largura aumenta para compensar

RESULTADO APÓS O BLOCK DESIGN

73,5% Top-1 com 0,89 ms — melhor acurácia que a baseline e latência ainda inferior a 1 ms.

Ideia: usar o orçamento economizado pelo ratio menor para aumentar a largura da rede.

O MACRODESIGN FOI SIMPLIFICADO

01 STEM

2 convoluções 3×3
com stride 2

02 DOWNSAMPLING

Camada separada
e mais profunda

03 CLASSIFICADOR

Global average pooling
+ camada linear

04 STAGE RATIO

1 : 1 : 7 : 1
mais blocos no 3º estágio




Figure 4. **Macro design.** (a) and (b), (c) and (d), (e) and (f) indicate the designs for stem, downsampling layer and classifier, respectively. RepViT has four stages with $\frac{H}{4} \times \frac{W}{4}$, $\frac{H}{8} \times \frac{W}{8}$, $\frac{H}{16} \times \frac{W}{16}$ and $\frac{H}{32} \times \frac{W}{32}$ resolutions respectively, where H and W denote the width and height of the input image. C represents the channel dimension and B denotes the batch size. The norm layer and nonlinearity are omitted.

Objetivo do macrodesign: reduzir gargalos de latência sem perder capacidade de representação.

KERNEL 3 × 3

Kernels maiores podem ampliar o campo receptivo, mas aumentam custo computacional e acesso à memória. O artigo prioriza 3 × 3 porque essas convoluções são muito bem otimizadas em compiladores móveis.

SE EM BLOCOS ALTERNADOS

A camada Squeeze-and-Excitation é usada no 1º, 3º, 5º... bloco de cada estágio. Assim, mantém ganho de acurácia com menor incremento de latência.

77,4%

Top-1

0,87 ms

latência no iPhone 12

sem destilação

RepViT-M0.9 final

Esse é o resultado da “modernização” completa do MobileNetV3-L.

VARIANTES COBREM 0,9 A 2,3 ms

ARQUITETURA

O sufixo Mx aproxima a latência do modelo no iPhone 12.



A família oferece diferentes pontos no orçamento de latência — de ultra-rápido a maior capacidade.

MELHOR ACURÁCIA POR LATÊNCIA

RESULTADOS




Figure 1. Comparison of latency and accuracy between RepViT (Ours) and others. The top-1 accuracy is tested on ImageNet-1K and the latency is measured by iPhone 12 with iOS 16. RepViT achieves the best trade-off between performance and latency.

80,3% @ 1,0 ms

RepViT-M1.0

primeiro lightweight model >80% em ~1 ms, segundo os autores

83,7% @ 2,3 ms

RepViT-M2.3

maior variante reportada no artigo

**RepViT desloca a fronteira
acurácia × latência em relação
aos modelos comparados.**

OS GANHOS EXISTEM SEM DESTILAÇÃO

Mesmo sem o professor RegNetY-16GF, a arquitetura continua competitiva.

77,4%

M0.9 • 0,9 ms

300 épocas, sem destilação

78,6%

M1.0 • 1,0 ms

300 épocas, sem destilação

82,5%


M2.3 • 2,3 ms

300 épocas, sem destilação

Model	Latency (ms)	Epochs	Top-1 (%)
MobileOne-S1 [60]	0.9	300	75.9
EfficientFormerV2-S0 [35]	0.9	300	73.7
FastViT-T8 [59]	0.9	300	75.6
RepViT-M0.9	0.9	300	77.4
RepViT-M1.0	1.0	300	78.6
MobileOne-S2 [60]	1.1	300	77.4
EdgeViT-XS [49]	3.6	300	77.5
EfficientFormerV2-S1 [35]	1.1	300	77.9
RepViT-M1.1	1.1	300	79.4
MobileOne-S4 [60]	1.6	300	79.4
FastViT-S12 [59]	1.5	300	79.8
EfficientFormerV2-S2 [35]	1.6	300	80.4
RepViT-M1.5	1.5	300	81.2
EfficientNet-B3 [57]	5.3	350	81.6
PoolFormer-S36 [69]	3.5	300	81.4
RepViT-M2.3	2.3	300	82.5

Conclusão: o ganho não depende apenas da destilação — as decisões arquiteturais sustentam o desempenho.

Encoder do SAM: ViT-B → RepViT-M2.3



≈ 10× mais rápido que o MobileSAM no MacBook M1 Pro

ZERO-SHOT CONTINUA COMPETITIVO

RepViT-SAM supera MobileSAM e ViT-B-SAM nos benchmarks reportados de edge detection, instance segmentation e SegInW.

REPViT TAMBÉM GENERALIZA

DOWNSTREAM




Table 5. **Object detection & instance segmentation** results on MS COCO 2017 with the Mask RCNN framework. **Semantic segmentation** results on ADE20K by integrating models into Semantic FPN. Backbone latencies are measured with image crops of 512×512 on iPhone 12 by Core ML Tools. * indicates that the model is initialized with weights pretrained for 450 epochs on ImageNet-1K.

Backbone	Latency ↓ (ms)	Object Detection			Instance Segmentation			Semantic
		AP ^{box}	AP ^{box} ₅₀	AP ^{box} ₇₅	AP ^{mask}	AP ^{mask} ₅₀	AP ^{mask} ₇₅	mIoU
ResNet18 [23]	4.4	34.0	54.0	36.7	31.2	51.0	32.7	32.9
PoolFormer-S12 [69]	7.5	37.3	59.0	40.1	34.6	55.8	36.9	37.2
EfficientFormer-L1 [36]	5.4	37.9	60.3	41.0	35.4	57.3	37.3	38.9
RepViT-M1.1	4.9	39.8	61.9	43.5	37.2	58.8	40.1	40.6
PoolFormer-S24 [69]	12.3	40.1	62.2	43.4	37.0	59.1	39.6	40.3
PVT-Small [63]	53.7	40.4	62.9	43.8	37.8	60.1	40.3	39.8
EfficientFormer-L3 [36]	12.4	41.4	63.9	44.7	38.1	61.0	40.4	43.5
RepViT-M1.5	6.4	41.6	63.2	45.3	38.6	60.5	41.5	43.6
EfficientFormerV2-S2* [35]	12.0	43.4	65.4	47.5	39.5	62.4	42.2	42.4
EfficientFormerV2-L* [35]	18.2	44.7	66.3	48.8	40.4	63.5	43.2	45.2
RepViT-M2.3*	9.9	44.6	66.1	48.8	40.8	63.6	43.9	46.1

Exemplo: em ADE20K, M2.3* chega a 46,1 mIoU em 9,9 ms; EfficientFormerV2-L* fica em 45,2 mIoU e 18,2 ms.

Fonte: Tabela 5 do artigo. * pré-treino de 450 épocas.

Table 6. Analyses on structural re-parameterization (SR).

SR	RepViT-M0.9	RepViT-M1.5	RepViT-M2.3
×	78.47%	82.09%	83.10%
✓	78.74%	82.29%	83.30%

Table 7. Analyses on SE layer placement.

SE	RepViT-M0.9		RepViT-M1.5	
	Top-1	Latency ↓	Top-1	Latency ↓
w/o SE	77.92%	0.83 ms	81.86%	1.48 ms
per block	78.75%	0.92 ms	82.29%	1.58 ms
ours	78.74%	0.87 ms	82.29%	1.52 ms

REPARAMETRIZAÇÃO ESTRUTURAL

Remover SR reduz a acurácia em todas as variantes avaliadas. O ganho é pequeno, mas consistente.

SE EM TODOS OS BLOCOS

Acurácia praticamente igual, mas com mais latência. O uso alternado mantém o benefício com menor custo.

Mensagem da ablação: cada escolha final está ligada a uma evidência experimental — não é apenas uma preferência de design.

PONTOS FORTES

- Latência medida em dispositivo real
- Modernização incremental e fácil de acompanhar
- Abstrações sustentam as escolhas de design
- Validação em classificação, detecção e segmentação

LIMITAÇÕES

- Avaliação móvel concentrada em iPhone 12 + Core ML
- Resultados de latência não garantem o mesmo comportamento em Android/NPUs
- Energia, memória e comportamento térmico não são aprofundados
- Treinos longos e destilação elevam o custo de desenvolvimento

artigo mostra que eficiência móvel depende tanto da arquitetura quanto do suporte do hardware.

CNNs AINDA TÊM ESPAÇO NO EDGE

RepViT mostra que decisões de design e medições no hardware real podem importar mais do que o rótulo “CNN” ou “ViT”.

Obrigado!



<https://forms.gle/rf5LnufSy3HBUTc66>



<https://github.com/Mestrado-Alvaro-Ribeiro/alvaro-ribeiro-985-tp558/tree/main/seminar2>