

OTIMIZAÇÃO DE HIPERPARÂMETROS

Grid Search, Random Search, TPE, Optuna e AutoDL

Bergstra et al. (2011) · Zimmer, Lindauer e Hutter (2021)

Inatel

Como encontrar boas configurações sem treinar tudo até o fim?

Da busca exaustiva a sistemas AutoDL com múltiplas fidelidades

AGENDA

- 01 Problema de HPO e espaço de busca
- 02 Grid Search, Random Search e TPE
- 03 Optuna e múltiplas fidelidades
- 04 BOHB e Auto-PyTorch
- 05 Resultados, limitações e futuro

O PROBLEMA DE OTIMIZAÇÃO

Cada configuração exige uma avaliação cara

$$\mathbf{x}^* = \arg \min \mathbf{f}(\mathbf{x})$$

- $\mathbf{x}$ Taxa de aprendizado, regularização, arquitetura e batch size
- $\mathbf{f}(\mathbf{x})$ Erro de validação depois de treinar o modelo

- Uma avaliação pode consumir horas de CPU ou GPU.

- O espaço mistura variáveis contínuas, discretas e condicionais.

- A função objetivo não oferece um gradiente direto para a busca.

O orçamento faz parte do problema

GRID SEARCH


Busca exaustiva em valores definidos previamente

4 valores

para cada parâmetro

5 parâmetros

no espaço de busca




Indicado para espaços pequenos e bem delimitados


- Testa todas as combinações da grade.
- É determinístico e fácil de reproduzir.
- O custo cresce pelo produto das opções.
- Repete valores mesmo em dimensões pouco importantes.

RANDOM SEARCH

Um baseline simples e forte



Poucos valores distintos repetidos em cada eixo




Mais valores amostrados nas dimensões relevantes

- Explora mais valores independentes.
- Permite paralelismo direto.
- Serve como referência experimental.
- Não utiliza os resultados anteriores.

Quando poucas dimensões importam, a busca aleatória cobre mais combinações úteis

RESULTADOS NO ARTIGO DE BERGSTRA

Erro de teste. Valores menores indicam melhor desempenho



14,13%

TPE no conjunto convex

44,55%

TPE no conjunto MRBI

TPE obteve o menor erro nos dois casos

OTIMIZAÇÃO SEQUENCIAL BASEADA EM MODELO

O histórico orienta a próxima avaliação

01

HISTÓRICO

Configurações e resultados observados

02

MODELO

Aproxima a função de avaliação

03

AQUISIÇÃO

Equilibra exploração e melhoria esperada

04

NOVO TRIAL

Treina e atualiza o histórico

EXPLORAÇÃO

Regiões pouco conhecidas

EXPLOTAÇÃO

Regiões já promissoras

TPE implementa esse ciclo com densidades probabilísticas

TPE

TREE-STRUCTURED
PARZEN ESTIMATOR

$l(x)$

boas configurações
 $y < y^*$

$g(x)$

demais
configurações
 $y \geq y^*$

Como funciona

- Divide os trials por um limiar de desempenho y^* .
- Modela $p(x | y)$ com duas densidades.
- Favorece pontos com alta razão $l(x) / g(x)$.
- Lida bem com espaços condicionais e estruturados em árvore.

O histórico concentra novas avaliações em regiões promissoras

OPTUNA

A biblioteca organiza a otimização como um Study

1

objective(trial)

Define a métrica e o espaço de busca

2

sampler

Sugere a próxima configuração

3

optimize

Executa e registra os trials

4

best_params

Retorna a melhor configuração

Componentes intercambiáveis

TPESampler ou RandomSampler

Pruners e persistência

Paralelismo e visualização

REPRODUÇÃO DIDÁTICA COM OPTUNA

RandomSampler e TPESampler sob as mesmas condições

ESPAÇO DE BUSCA

- learning_rate: 10^{-5} a 10^{-1} em escala log
- dropout: 0 a 0,6
- width: 32, 64, 128 ou 256
- 60 trials com a mesma semente

O NOTEBOOK DEMONSTRA

- Criação de dois Studies
- Comparação do melhor valor
- Inspeção de best_params
- Substituição fácil por um treino real

Mesmo espaço + mesma semente + mesmo orçamento

FIDELIDADE ÚNICA E MÚLTIPLAS FIDELIDADES

O orçamento por configuração também pode ser otimizado

FIDELIDADE ÚNICA

- Todas as configurações treinam até o fim.
- Comparação final mais direta.
- Custo elevado em deep learning.

MÚLTIPLAS FIDELIDADES

- Muitas configurações recebem poucas épocas.
- Somente as promissoras ganham mais orçamento.
- Exige correlação entre desempenho inicial e final.

Pergunta-chave: poucas épocas predizem o resultado final?

HYPERBAND E SUCCESSIVE HALVING

O orçamento aumenta somente para as configurações promovidas

27 CONFIGURAÇÕES

poucas épocas

9 PROMOVIDAS

mais épocas

3 PROMOVIDAS

orçamento maior

1 FINALISTA

treino completo

Muitas avaliações baratas

Poucas avaliações completas

BOHB

Otimização bayesiana com alocação adaptativa de orçamento

HYPERBAND

Decide quanto orçamento cada configuração recebe

- Avalia muitas configurações com orçamento baixo.



MODELO KDE

Orienta novas amostras para regiões promissoras

- Promove as melhores para orçamentos maiores.



BOHB

- Mantém parte das amostras aleatórias para preservar exploração.

No Auto-PyTorch: 12, 25 e 50 épocas

AUTO- PYTORCH

DE HPO A AUTODL

Busca

BOHB

Warm start

16 configs

100 tarefas de meta-treinamento

O que o sistema automatiza

- Pré-processamento e arquitetura da rede.
- Hiperparâmetros de treinamento.
- Portfólio meta-aprendido para warm start.
- Seleção automática de ensembles.

Foco principal do artigo: dados tabulares

Maior automação, maior complexidade operacional

PIPELINE DO AUTO-PYTORCH

Quatro componentes transformam a busca em um sistema AutoDL

01

PORTFÓLIO

Configurações fortes para
iniciar a busca

02

BOHB

Busca orientada e
múltiplas fidelidades

03

PIPELINE

Pré-processamento, rede
e treinamento

04

ENSEMBLE

Combina modelos já
avaliados


- Meta-learning reduz o tempo até uma boa configuração.

- Múltiplas fidelidades evitam treinos completos desnecessários.

Ensemble: redes, RF, Extra Trees, LightGBM, CatBoost e k-NN

LCBENCH E CORRELAÇÃO ENTRE FIDELIDADES

Correlação de Spearman entre rankings. Valores maiores indicam maior estabilidade



2.000 × 35

configurações × datasets

3 sementes

3 orçamentos

≈ 1.500 h de CPU

custo de coleta


Portfólio de 10 configs

arrendimento médio < 0,1%

Correlação: 0,88 a 0,96

RESULTADOS DO AUTO-PYTORCH

Exemplo reportado no conjunto covertype



LEITURA RÁPIDA

- No covertype, o erro caiu de 31,78% para 3,14%.
- Três workers alcançaram speedup de 3× ou mais nas maiores tarefas.
- Com ensemble e stacking, o AutoGluon obteve pequena vantagem.

Não há superioridade universal

COMPARAÇÃO PRÁTICA

Algoritmos, ferramenta e sistema AutoDL ocupam níveis diferentes

Opção	Natureza	Quando usar	Principal cuidado
Grid Search	Algoritmo	Espaço pequeno	Explosão combinatória
Random Search	Algoritmo	Baseline paralelizável	Não aprende
TPE + Optuna	Algoritmo + ferramenta	Avaliações caras	Precisa de histórico útil
BOHB	Otimizador multifidelidade	Métrica intermediária confiável	Pode eliminar bons candidatos
Auto-PyTorch	Sistema AutoDL	Pipeline tabular completa	Custo e complexidade

Auto-PyTorch usa BOHB nos experimentos do artigo, não Optuna

LIMITAÇÕES E CUIDADOS

Os resultados dependem do problema e do desenho experimental

BERGSTRA ET AL. (2011)

- Comparação sequencial detalhada em duas tarefas de DBN.
- Um surrogate inadequado pode levar a um ótimo local.
- A vantagem do TPE sobre GP exigia mais evidência empírica.

AUTO-PYTORCH (2021)

- LCBench usa um espaço menor que o sistema completo.
- A avaliação principal usa apenas 8 datasets de meta-teste.
- Acurácia limita a análise de dados desbalanceados.
- Portfólio depende de tarefas anteriores representativas.

Ensembles podem sobreajustar a validação reutilizada na busca

HPO também pode sobreajustar a validação. O teste deve permanecer isolado.

CONCLUSÕES

Cinco ideias para levar da apresentação

- | | | |
|----|----------------------|---|
| 01 | Grid Search | Funciona em espaços pequenos, mas escala mal. |
| 02 | Random Search | É o baseline simples, robusto e paralelizável. |
| 03 | TPE | Usa o histórico para concentrar novas avaliações. |
| 04 | BOHB | Distribui o orçamento e mantém busca orientada. |
| 05 | Auto-PyTorch | Integra HPO, meta-learning e ensemble. |

O melhor método transforma o orçamento disponível em evidência confiável

TRABALHOS FUTUROS

Extensões propostas pelos autores do Auto-PyTorch

- | | | |
|----|---------------|--|
| 01 | GENERALIZAÇÃO | Melhorar a seleção de ensembles sem sobreajustar |
| 02 | AUTO-SKLEARN | Integrar modelos neurais e não neurais |
| 03 | LCBENCH | Adicionar datasets maiores e mais fidelidades |
| 04 | IMPORTÂNCIA | Restringir o espaço aos parâmetros relevantes |
| 05 | MODALIDADES | Expandir o núcleo para imagem e novas tarefas |

inatel.tecnologias 
inatel.tecnologias 
inateloficial 
company/inatel 
www.inatel.br 

Campus em Santa Rita do Sapucaí
Minas Gerais - Brasil
Av. João de Camargo, 510
Centro - 37536-001

PERGUNTAS?

REFERÊNCIAS PRINCIPAIS

Bergstra et al. Algorithms for Hyper-Parameter Optimization. NeurIPS, 2011.
Zimmer, Lindauer e Hutter. Auto-PyTorch. TPAMI, 2021.
Falkner, Klein e Hutter. BOHB. ICML, 2018.
Optuna 3.4.1. Documentação oficial.

Inatel




_o futuro
não tem hora,
mas tem lugar.



<https://forms.gle/zmFadJYd9DaBCgT87>




<https://github.com/Mestrado-Alvaro-Ribeiro/alvaro-ribeiro-985-tp558/tree/main/seminar3>




GRID SEARCH

Grade fixa
Todas as combinações




RANDOM SEARCH

Amostragem aleatória
N configurações




TPE

Histórico dos trials
 $l(x) / g(x)$



OPTUNA

Study e Trial
Sampler + Pruner



BOHB

12 → 25 → 50 épocas
Promove os melhores



AUTO-PYTORCH


Portfólio + BOHB
Pipeline + Ensemble

COMO GRID SEARCH E RANDOM SEARCH FUNCIONAM

GRID SEARCH



RANDOM SEARCH



POR QUE ISSO ECONOMIZA RECURSOS: Garante a exploração do espaço de busca. O Grid é metódico em espaços pequenos e simples; o Random é eficiente em espaços grandes, evitando o desperdício em áreas ruins.

COMO O TPE ESCOLHE O PRÓXIMO TRIAL

1. LÊ O HISTÓRICO



Usa os resultados dos trials anteriores.

2. DEFINE O LIMAR y^*



Separa bons e maus resultados.

3. SEPARA CONFIGURAÇÕES




Modela duas distribuições.

4. GERA CANDIDATOS



Amostra novas configurações usando $l(x)$ e $g(x)$.

5. ESCOLHA



Razão $l(x)/g(x)$ - quanto maior, melhor.




POR QUE ISSO ECONOMIZA RECURSOS: Não utiliza configurações aleatórias; aprende com o histórico e foca a amostragem nas regiões com maior probabilidade de encontrar um hiperparâmetro com melhor potencial.

O QUE ACONTECE DENTRO DO OPTUNA



POR QUE ISSO ECONOMIZA RECURSOS: Monitoramento e o Pruner (podador) interrompem precocemente o treinamento de modelos com desempenho ruim, poupando tempo de GPU/CPU.

COMO BOHB E AUTO-PYTORCH TRABALHAM JUNTOS



POR QUE ISSO ECONOMIZA RECURSOS: BOHB avalia rápido e descarta modelos ruins (Hyperband) e foca nas melhores configurações (TPE). O Auto-PyTorch automatiza o pipeline de treinamento, e o Ensemble melhora a performance sem treinar um único modelo gigante do zero.