
Instituto Nacional de Telecomunicações
510
Inatel



D-FINE

Refinamento fino de distribuições para detecção de objetos

Inatel

AGENDA

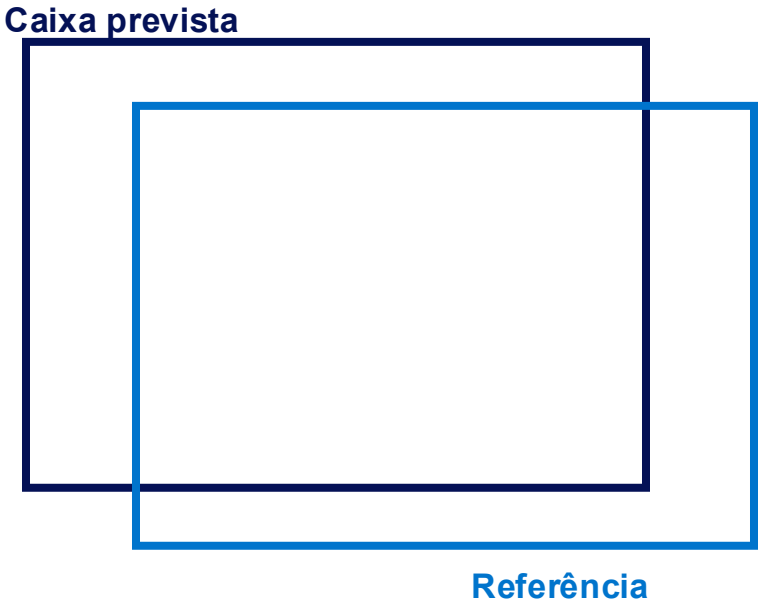
- Contexto e motivação
- D-FINE: FDR e GO-LSD
- Resultados experimentais e ablações
- Discussão crítica e conclusões

Inatel

POR QUE A LOCALIZAÇÃO IMPORTA?

Duas tarefas na detecção de objetos

Classificação: identificar o que foi detectado.
Localização: delimitar onde o objeto está.



IoU = área de interseção / área de união

Deslocamentos pequenos nas bordas já podem reduzir o AP.

Inatel

DE DETR AO RT-DETR

Predição de conjuntos com Transformer

Backbone + encoder

Representações visuais multiescala

→

Decoder e queries

Predição de classes e caixas

→

Correspondência 1:1

Matching húngaro no treinamento

RT-DETR adapta a família para menor latência, preservando a detecção end-to-end.

Inatel

O PROBLEMA DA REGRESSÃO DE CAIXAS

- Predição tradicional: coordenadas (x, y, w, h) ou distâncias às bordas.
- Perdas L1 e IoU avaliam a qualidade da caixa final.
- O treinamento fornece pouca estrutura para corrigir cada borda de forma granular.
- Erros de localização são especialmente importantes em alvos pequenos e ambíguos.

Pergunta central: como aperfeiçoar a regressão sem aumentar excessivamente o custo?

Inatel

A PROPOSTA D-FINE

Duas contribuições centrais

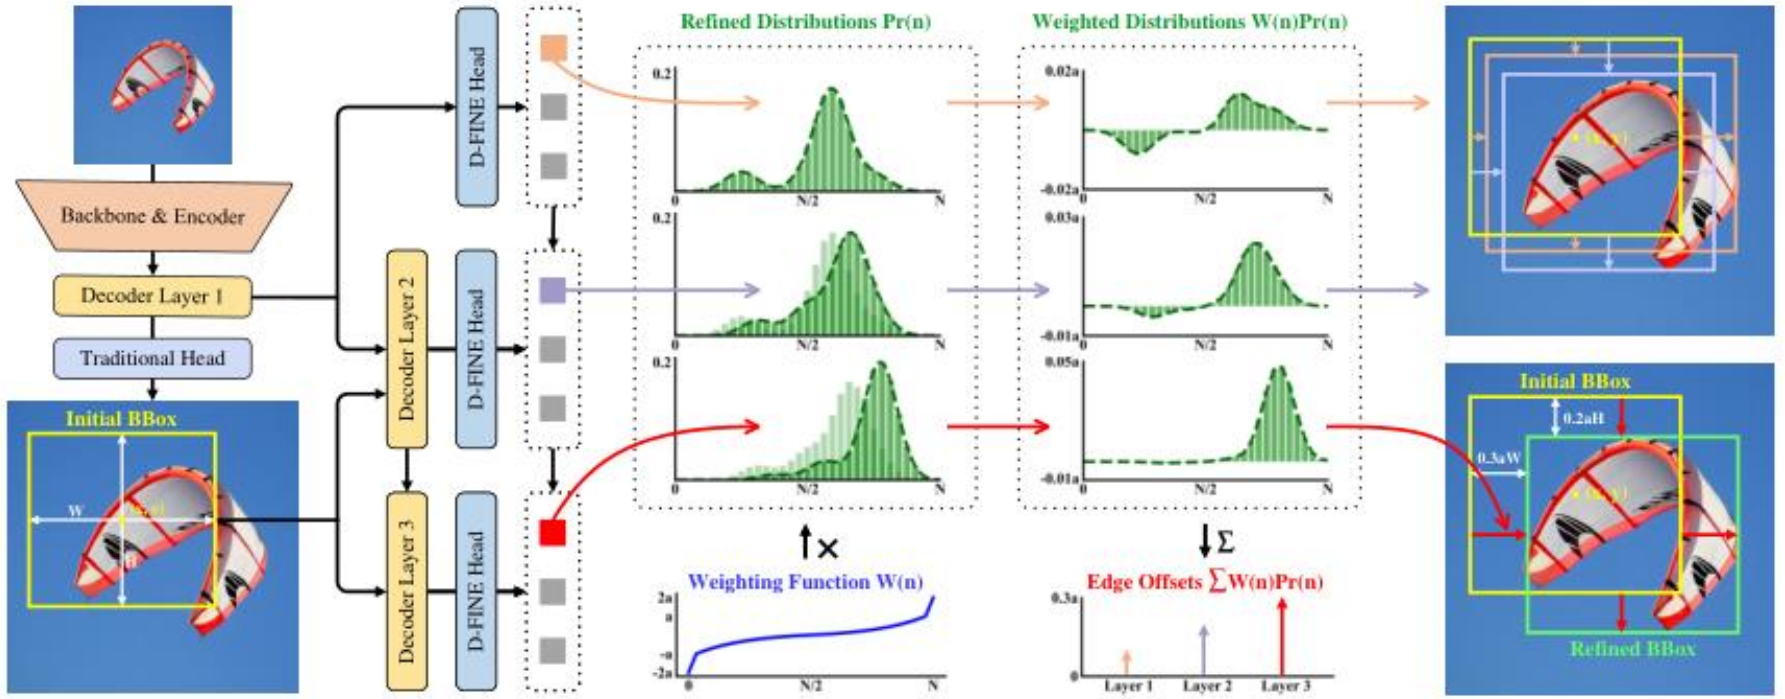
1. **FDR — Fine-grained Distribution Refinement**
   Distribuições discretas para refinar iterativamente as quatro bordas.

2. **GO-LSD — Global Optimal Localization Self-Distillation**
   A última camada ensina as anteriores a localizar melhor.

Base: RT-DETR + alterações arquiteturais de eficiência.

Inatel

FDR: REFINAMENTO DE DISTRIBUIÇÕES



Cada camada refina as distribuições de correção das quatro bordas.

Fonte: Peng et al. (2024), Figura 2, p. 5 (recorte).

Inatel

FDR: FORMULAÇÃO MATEMÁTICA

Atualização residual dos logits

$$p_e^{(j)}(n) = \text{softmax}[z_e^{(j-1)}(n) + \Delta z_e^{(j)}(n)]$$

Conversão da distribuição em deslocamento

$$d_e^{(j)} = d_e^{(0)} + s_e \cdot \Sigma_n \, w(n) \, p_e^{(j)}(n)$$

e: borda • w(n): deslocamento do bin • s_e: W ou H da caixa inicial

Fonte: Peng et al. (2024), Equações 2 e 3, pp. 4–5.

Inatel

PERDA FGL: LOCALIZAÇÃO FINA

Fine-Grained Localization (FGL)

- Deslocamento verdadeiro localizado entre dois bins vizinhos.
- Entropia cruzada interpolada orienta a distribuição por borda.
- Ponderação por IoU incorpora a qualidade da localização.
- A FGL complementa as perdas de classificação e de caixa.

Fonte: Peng et al. (2024), Equação 5, p. 5.

Inatel

COMO A FDR MUDA A PREDIÇÃO?

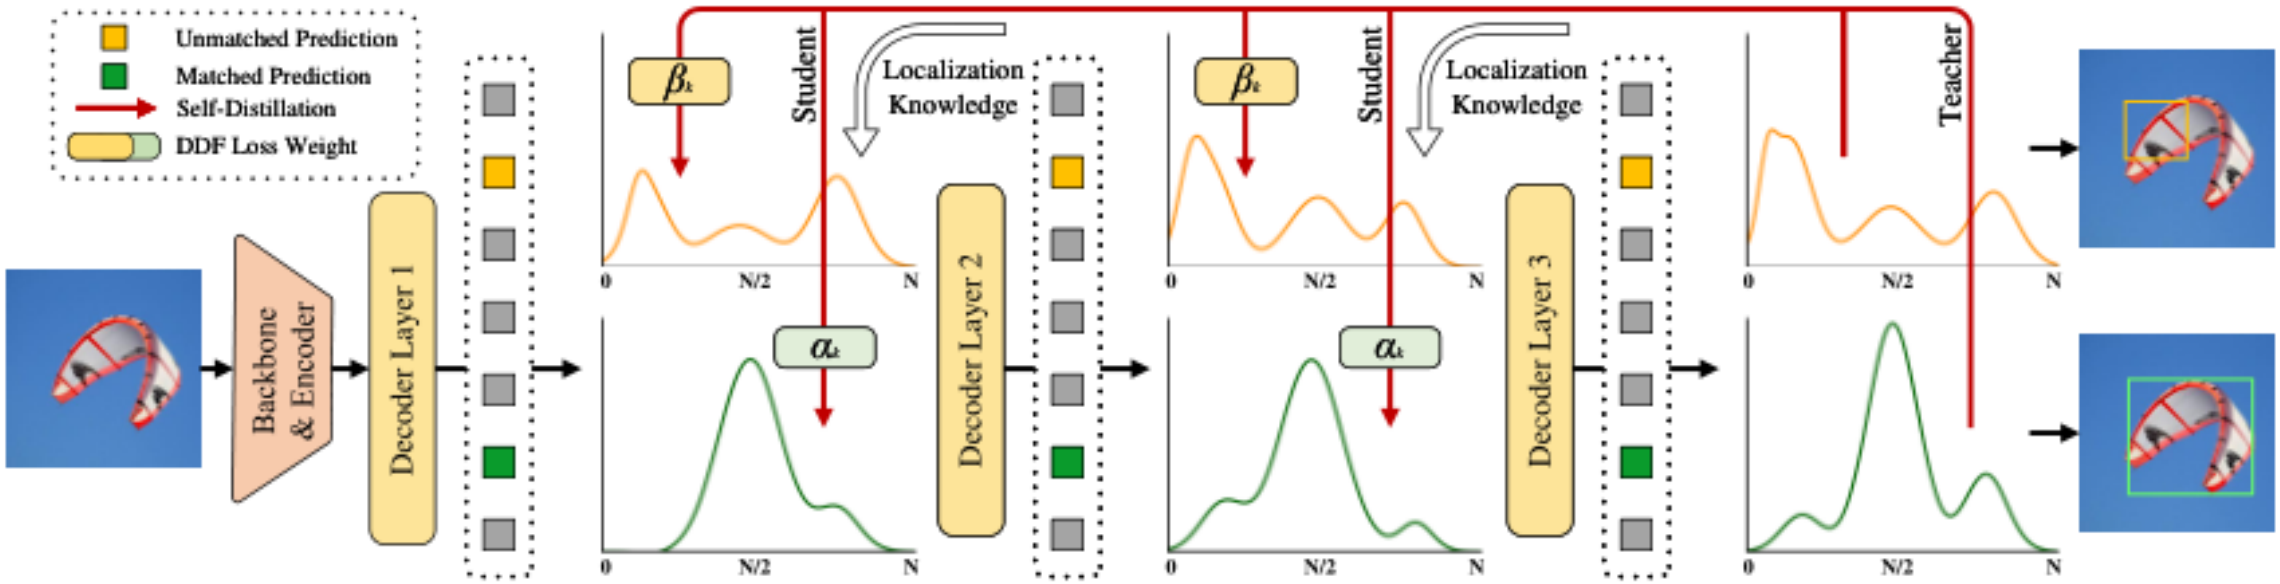
Refinamento residual da caixa inicial

Caixa inicial	→	Distribuições	→	Offsets	→	Caixa refinada
(x, y, W, H)		topo · base · esquerda · direita		Σ w(n) · p(n)		limites ajustados

A distribuição descreve correções relativas, não probabilidades de caixas completas.

Inatel

GO-LSD: AUTO DESTILAÇÃO ENTRE CAMADAS



A última camada (professora) orienta as distribuições das camadas iniciais.

Fonte: Peng et al. (2024), Figura 3, p. 6 (recorte).

Inatel

GO-LSD: MATCHING E PERDA DDF

1. **Matching global de localização**
   União dos índices húngaros de todas as camadas.

2. **Distilação por divergência KL**
   Comparação entre distribuições rasas e final com temperatura T.

3. **Ponderação desacoplada**
   Matched: IoU | Unmatched: confiança de classificação.

Fonte: Peng et al. (2024), seção 4.2 e Equação 6, p. 6.

Inatel

GO-LSD: O QUE MUDA NO TREINAMENTO?

Treinamento

- Supervisão adicional nas camadas rasas.
- Uso da própria camada final como professora.
- Perda DDF orientada à localização.

Inferência: não requer uma segunda rede professora.

Inatel

OTIMIZAÇÕES DE EFICIÊNCIA

- Remoção de projeções do decoder e inclusão de target gating.
- Substituição de CSP por GELAN com dimensão interna reduzida.
- Amostragem multiescala redistribuída: 3 / 6 / 3 pontos.
- Estratégia de treinamento inspirada no RT-DETRv2.

D-FINE completo ≠ RT-DETR com duas novas perdas.

PROTOCOLO EXPERIMENTAL

Precisão

COCO val2017
AP médio em IoU 0,50:0,95
AP_{50}, AP_{75}, APS, APM e APL

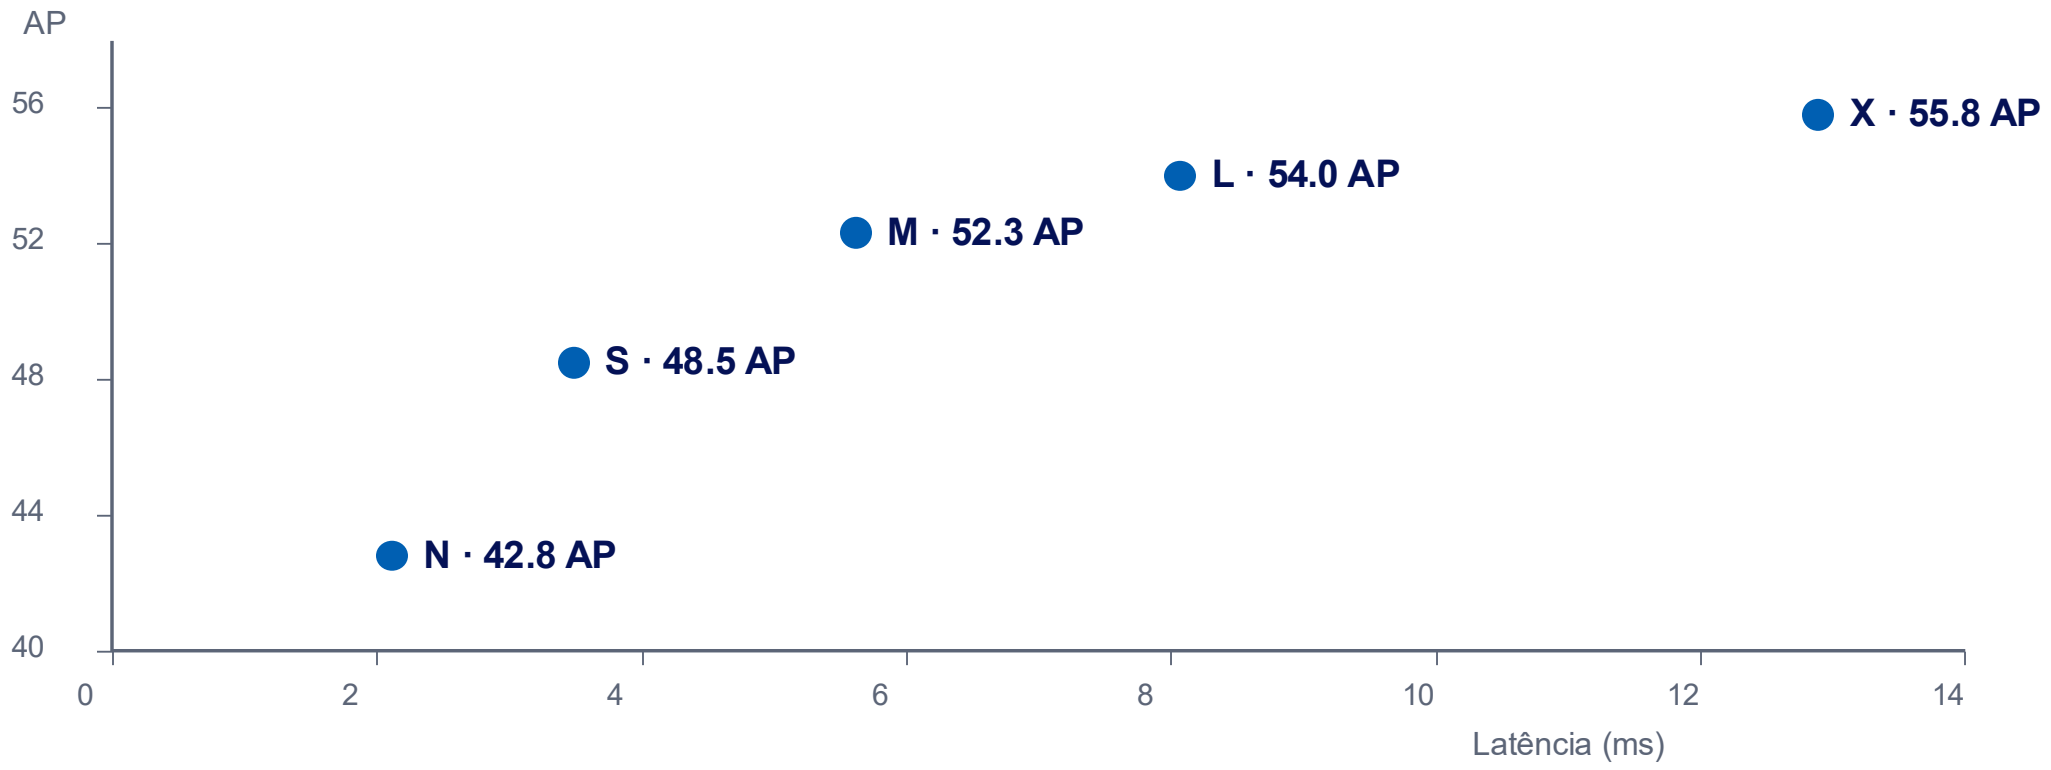
Velocidade

GPU NVIDIA T4
TensorRT FP16 • lote 1
Latência ponta a ponta (ms)

Os números não descrevem automaticamente desempenho em CPU, PyTorch ou outros dispositivos.

Inatel

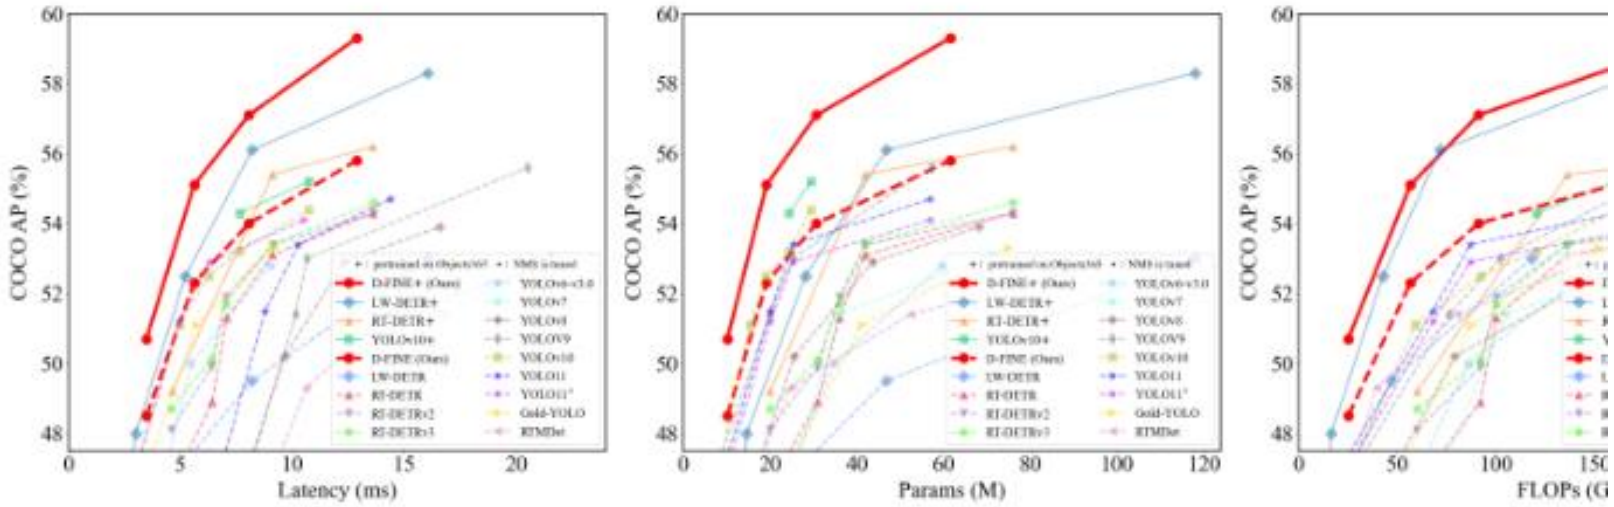
FAMÍLIA D-FINE: AP VERSUS LATÊNCIA



D-FINE-N/S/M/L/X: modelos treinados em COCO. Dados: repositório oficial e artigo.

Inatel

COMPARAÇÃO VISUAL DO ARTIGO



Leitura rápida

D-FINE desloca a fronteira de desempenho, combinando maior AP com baixa latência. A comparação é medida em TensorRT FP16 na NVIDIA T4. A figura ajuda a visualizar que o ganho não vem apenas do aumento de parâmetros.

Figura 1 do artigo: comparação com outros detectores em termos de latência, tamanho do modelo e custo computacional.

Inatel

D-FINE FRENTE A DETECTORES DE TEMPO REAL

Modelo	Parâmetros	GFLOPs	AP	Latência
RT-DETR-HG-L	32 M	107	53,0	9,25 ms
YOLOv10-L	24 M	120	53,2	7,66 ms
YOLO11-L	25 M	87	53,4	10,28 ms
D-FINE-L	**31 M**	**91**	**54,0**	**8,07 ms**

Mesma base COCO, conforme Tabela 1. Desempenhos dependem dos protocolos reportados.

Inatel

O EFEITO DO PRÉ-TREINAMENTO

	COCO apenas		Objects365 → COCO	
D-FINE-L	54,0	→	**57,1**	AP
D-FINE-X	55,8	→	**59,3**	AP

O pré-treinamento amplia o orçamento de dados: resultados devem ser separados.

Fonte: Peng et al. (2024), Tabela 1. Números da versão original do artigo.

Inatel

ABLAÇÃO: DE RT-DETR A D-FINE

Etapa	AP COCO	GFLOPs	Latência
RT-DETR-HGNetv2-L	53,0	110	9,25 ms
+ ajustes de eficiência	53,0	91	7,90 ms
+ FDR	53,5	91	8,07 ms
+ GO-LSD	**54,0**	**91**	**8,07 ms**

Arquitetura reduz custo. FDR e GO-LSD elevam AP sobre o baseline otimizado.

Inatel

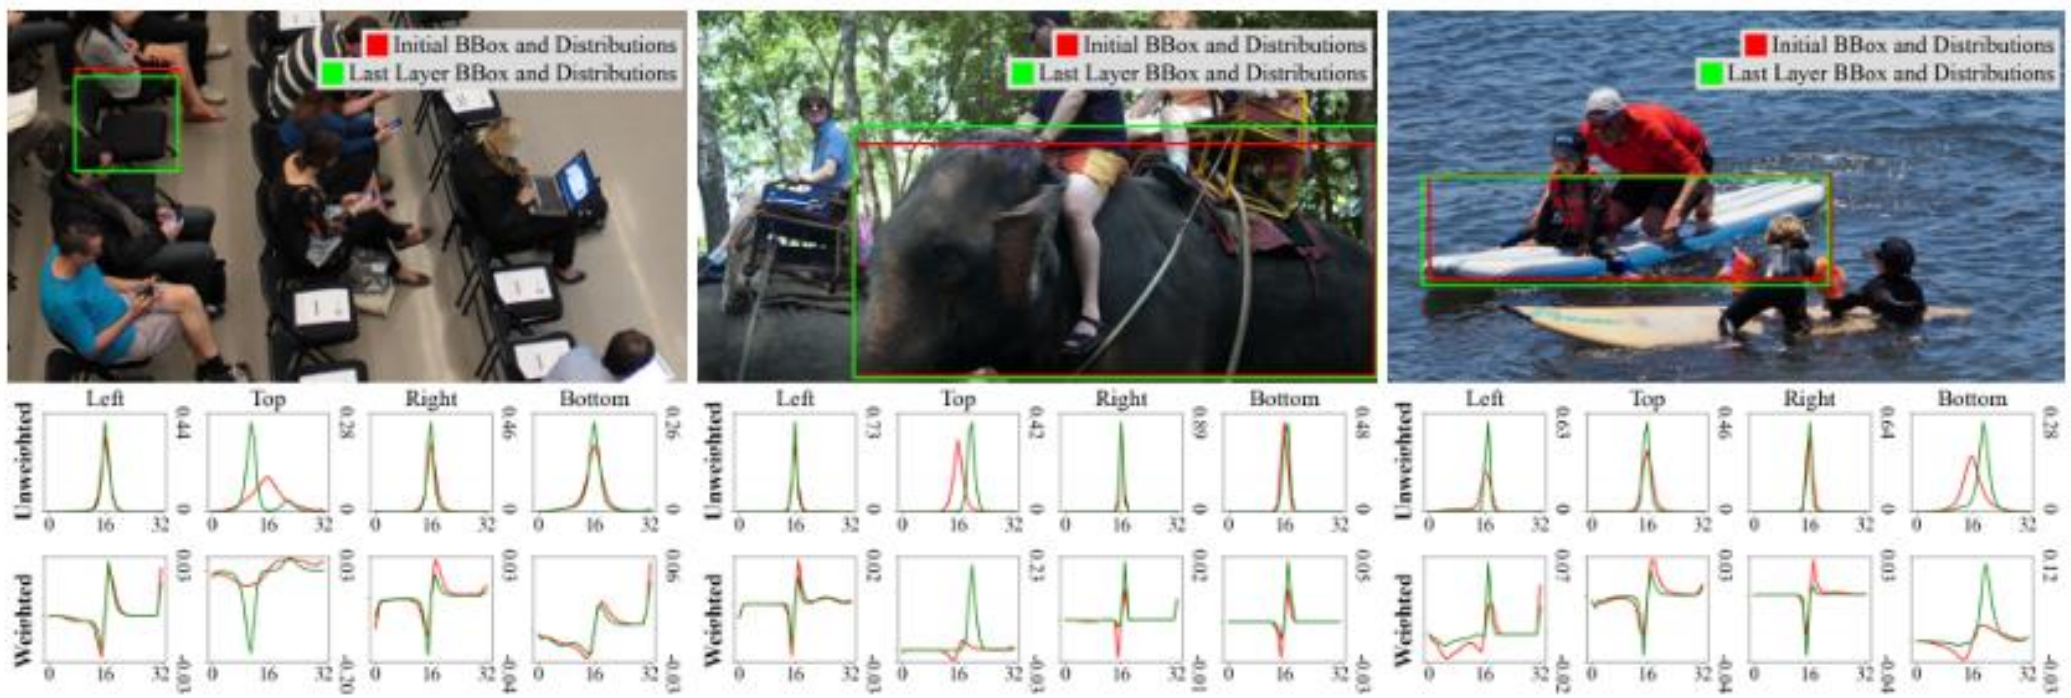
ABLAÇÃO: DESTILAÇÃO DE LOCALIZAÇÃO

Método	AP	Tempo/época	Memória
Baseline	53,0	29 min	8.552 MB
Logit Mimicking	52,6	31 min	8.554 MB
Feature Imitation	52,9	31 min	8.554 MB
Baseline + FDR	53,8	30 min	8.730 MB
GO-LSD	**54,5**	**31 min**	**8.734 MB**

Atenção: configuração de ablação sem otimizações leves; não é o D-FINE-L completo.

Inatel

VISUALIZAÇÃO DOS REFINAMENTOS



Vermelho: caixa inicial | Verde: caixa após o refinamento

Fonte: Peng et al. (2024), Figura 4, p. 10 (três exemplos qualitativos).

Inatel

EXEMPLOS QUALITATIVOS DO D-FINE-X



O que observar

Robustez em oclusão e cenas densas.
Comportamento sob baixa iluminação e motion blur.
Diversidade de categorias e situações reais.

Inatel

LIMITAÇÕES E LEITURA CRÍTICA

- Avaliação quantitativa concentrada no conjunto COCO val2017.
- Latência reportada para TensorRT FP16 na GPU NVIDIA T4.
- Objects365 aumenta o orçamento de pré-treinamento.
- Não há avaliação abrangente da calibração de incerteza das caixas.
- Resultados do sistema combinam método e otimizações arquiteturais.

CONCLUSÕES

- A regressão é reformulada como refinamento progressivo de distribuições.
- FDR oferece sinais mais granulares para ajustar as quatro bordas.
- GO-LSD melhora as camadas rasas usando a camada final como professora.
- D-FINE-L: 54,0 AP e 8,07 ms no protocolo de avaliação do artigo.

Mensagem-chave: melhor representação + supervisão da localização.

Inatel

REFERÊNCIAS

PENG, Y. et al. D-FINE: Redefine Regression Task in DETRs as Fine-grained Distribution Refinement. arXiv:2410.13842, 2024. ICLR 2025 Spotlight.

Artigo: https://arxiv.org/abs/2410.13842

Código: https://github.com/Peterande/D-FINE

Todas as figuras e os resultados apresentados são atribuídos à obra original.

Inatel


inatel.tecnologias
inatel.tecnologias
inateloficial
company/inatel
www.inatel.br
Campus em Santa Rita do Sapucaí
Minas Gerais - Brasil
Av. João de Camargo, 510
Centro - 37536-001
OBRIGADO!
Perguntas?
Inatel
_o futuro
não tem hora,
mas tem lugar.
• Seminário de Mestrado · D-FINE



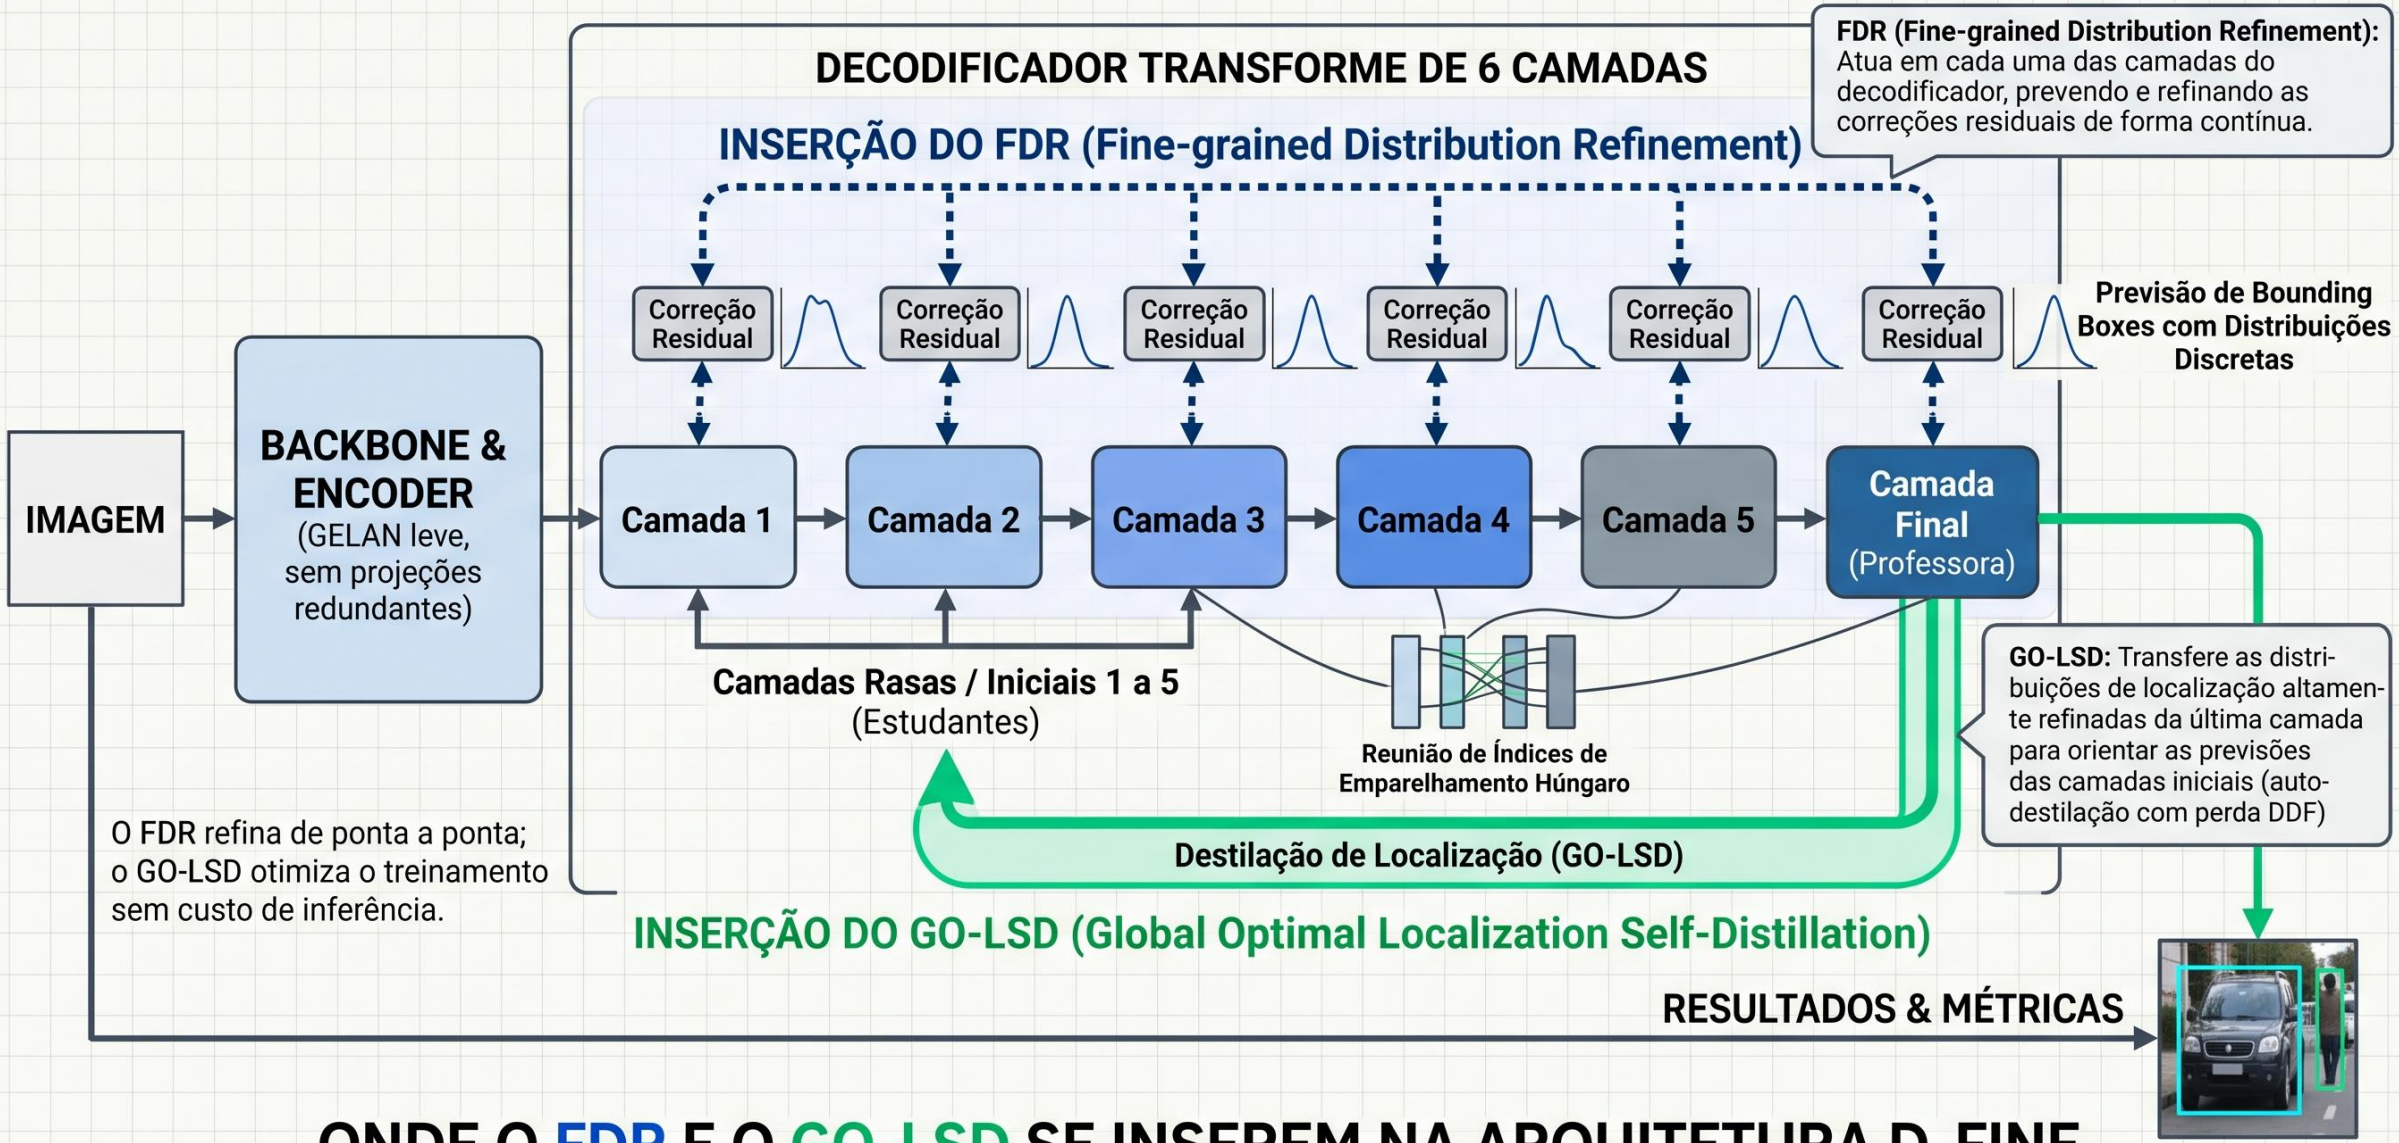
https://forms.gle/12QtepQPTXS1Pej17



https://github.com/Mestrado-Alvaro-Ribeiro/alvaro-ribeiro-985-tp558/tree/main/seminar4

Inatel

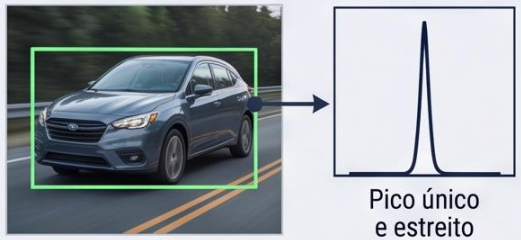
ONDE O FDR E O GO-LSD SE INSEREM NA ARQUITETURA D-FINE



ONDE O FDR E O GO-LSD SE INSEREM NA ARQUITETURA D-FINE

1. REGRESSÃO TRADICIONAL vs. FINE-GRAINED DISTRIBUTION REFINEMENT (FDR)

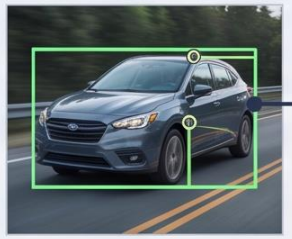
Regressão Tradicional (Dirac)



Pico único
e estreito

- Coordenadas Fixas (Dirac)
- Trata bordas como valores precisos
- Nenhum modelo de incerteza
- Supervisão L1/IoU

D-FINE (FDR)

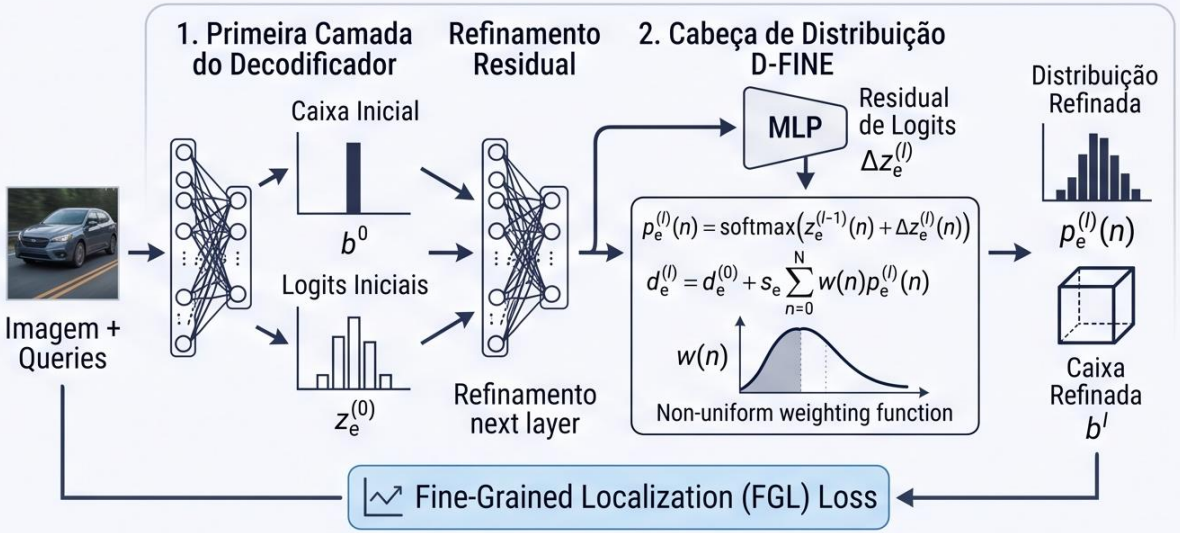




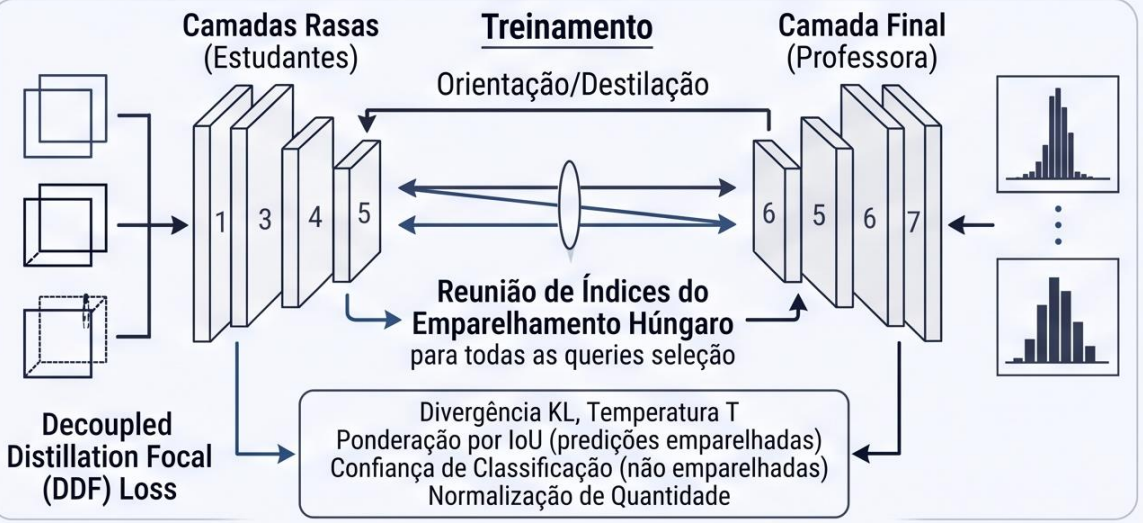
Vários bins,
mais difusa

- Distribuição Discreta de Correções (FDR)
- Representa correções sucessivas
- Modelos de ambiguidade interna
- Ajustes finos de bordas

2. FLUXO DE REFINAMENTO DE DISTRIBUIÇÕES FDR



3. GLOBAL OPTIMAL LOCALIZATION SELF-DISTILLATION (GO-LSD)



4. AJUSTES DE EFICIÊNCIA DE ARQUITETURA

Melhorias de Eficiência D-FINE

1. **Remoção de Projeções do Decodificador** (menos camadas)
2. **Target Gating** (introduzida após de removias)
3. **Troca de Blocos CSP por GELAN** (GELAN com dimensão interna reduzida)
4. **Redistribuição de Pontos de Amostragem** (entre escalas,
5. **Estratégia de Treinamento RT-DETRv2** (bag-of-freebies)

5. **Eficiência de Treinamento RT-arquitetura**
(avsetiros stotruos

