
Instituto Nacional de Telecomunicações
510
Inatel

# INFERÊNCIA DE IA NA BORDA

Benchmarks de frameworks, desempenho e eficiência energética

Inatel

# AGENDA

- Fundamentos e métricas de inferência
- Artigo 1 · Frameworks em visão industrial
- Artigo 2 · Aceleração na Jetson AGX Orin
- Artigo 3 · Eficiência energética em detecção
- Comparação crítica e conclusões

Inatel

# POR QUE OTIMIZAR A INFERÊNCIA NA BORDA?

**A escolha do runtime determina se o modelo é viável**

## 01

### LATÊNCIA

**Responder a tempo**

Sistemas de inspeção e controle dependem de atrasos reduzidos.

## 02

### ENERGIA

**Operar por mais tempo**

W e J/inferência importam em sistemas com limite térmico.

## 03

### QUALIDADE

**Manter precisão**

Exportação e INT8 podem alterar o mAP ou a Top-1.

> **Desempenho de inferência é uma propriedade do sistema completo.**

Inatel

# ONDE O TEMPO DE EXECUÇÃO É GASTO?

## Pipeline típico de visão computacional




**Latência do modelo ≠ tempo total por frame ≠ FPS sustentado do pipeline**

Inatel

# TRÊS ARTIGOS, TRÊS PERSPECTIVAS

**Uma questão comum, três experimentos diferentes**

## 01

### VISÃO INDUSTRIAL

4 frameworks · CPU e GPU

**Tempo de inferência**

## 02

### JETSON AGX ORIN

5 frameworks · CNNs e Transformer

**Latência · RAM · W**

## 03

### EFICIÊNCIA ENERGÉTICA

YOLOv8l e RT-DETR-l em edge

**mAP · FPS · FPS/W**

> **A comparação exige respeitar o protocolo de cada artigo.**

Inatel

# QUAIS MÉTRICAS REALMENTE IMPORTAM?

**O que cada métrica responde?**

## LATÊNCIA (ms)

**Quanto tempo?**

Tempo por execução do modelo ou por entrada.

## THROUGHPUT

**Quantas por segundo?**

Amostras/s; normalmente depende do tamanho do lote.

## FPS/W

**Qual a eficiência?**

Quadros processados por segundo por watt.

## mAP50–95

**Com qual precisão?**

Qualidade de detecção em múltiplos limiares de IoU.

> **Mesma arquitetura ≠ mesmo resultado em outro hardware ou runtime.**

Inatel

# ARTIGO 1 · VISÃO INDUSTRIAL

Benchmark de inferência entre CPUs, GPUs e runtimes · Fernandez et al. (2026)

Inatel

# ARTIGO 1 · METODOLOGIA EXPERIMENTAL

## Controle do modelo e da entrada por configuração

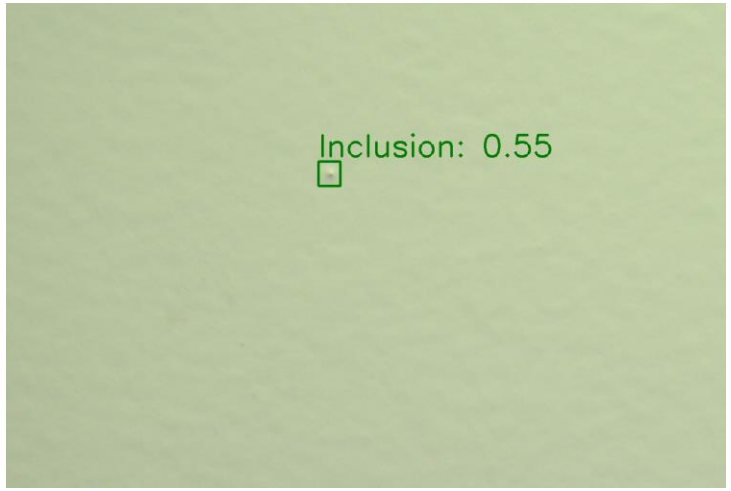
| | |
|---|---|
| **Frameworks** | PyTorch, ONNX Runtime, OpenVINO e TensorRT. |
| **Plataformas** | Três desktops com CPUs Intel e GPUs NVIDIA; Jetson AGX Orin 32 GB. |
| **Precisão** | FP32 em todas as configurações avaliadas. |
| **Medição** | 1.000 execuções; 10 descartadas; média ± desvio nas 990 restantes; batch 1. |

*Fonte: Fernandez et al. (2026), Seção II e Tabela I.*

Inatel

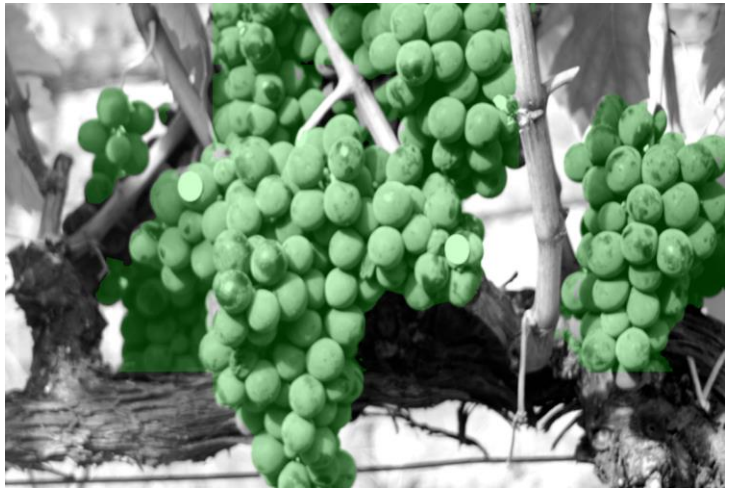
# ARTIGO 1 · TRÊS TAREFAS DE VISÃO

## Uma comparação que inclui CNNs e Transformer



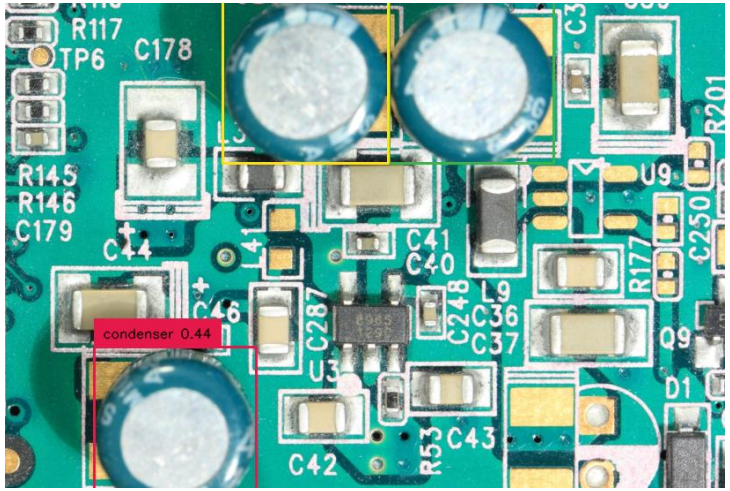

### YOLOv8

Detecção de defeitos



### UNet

Segmentação de uvas



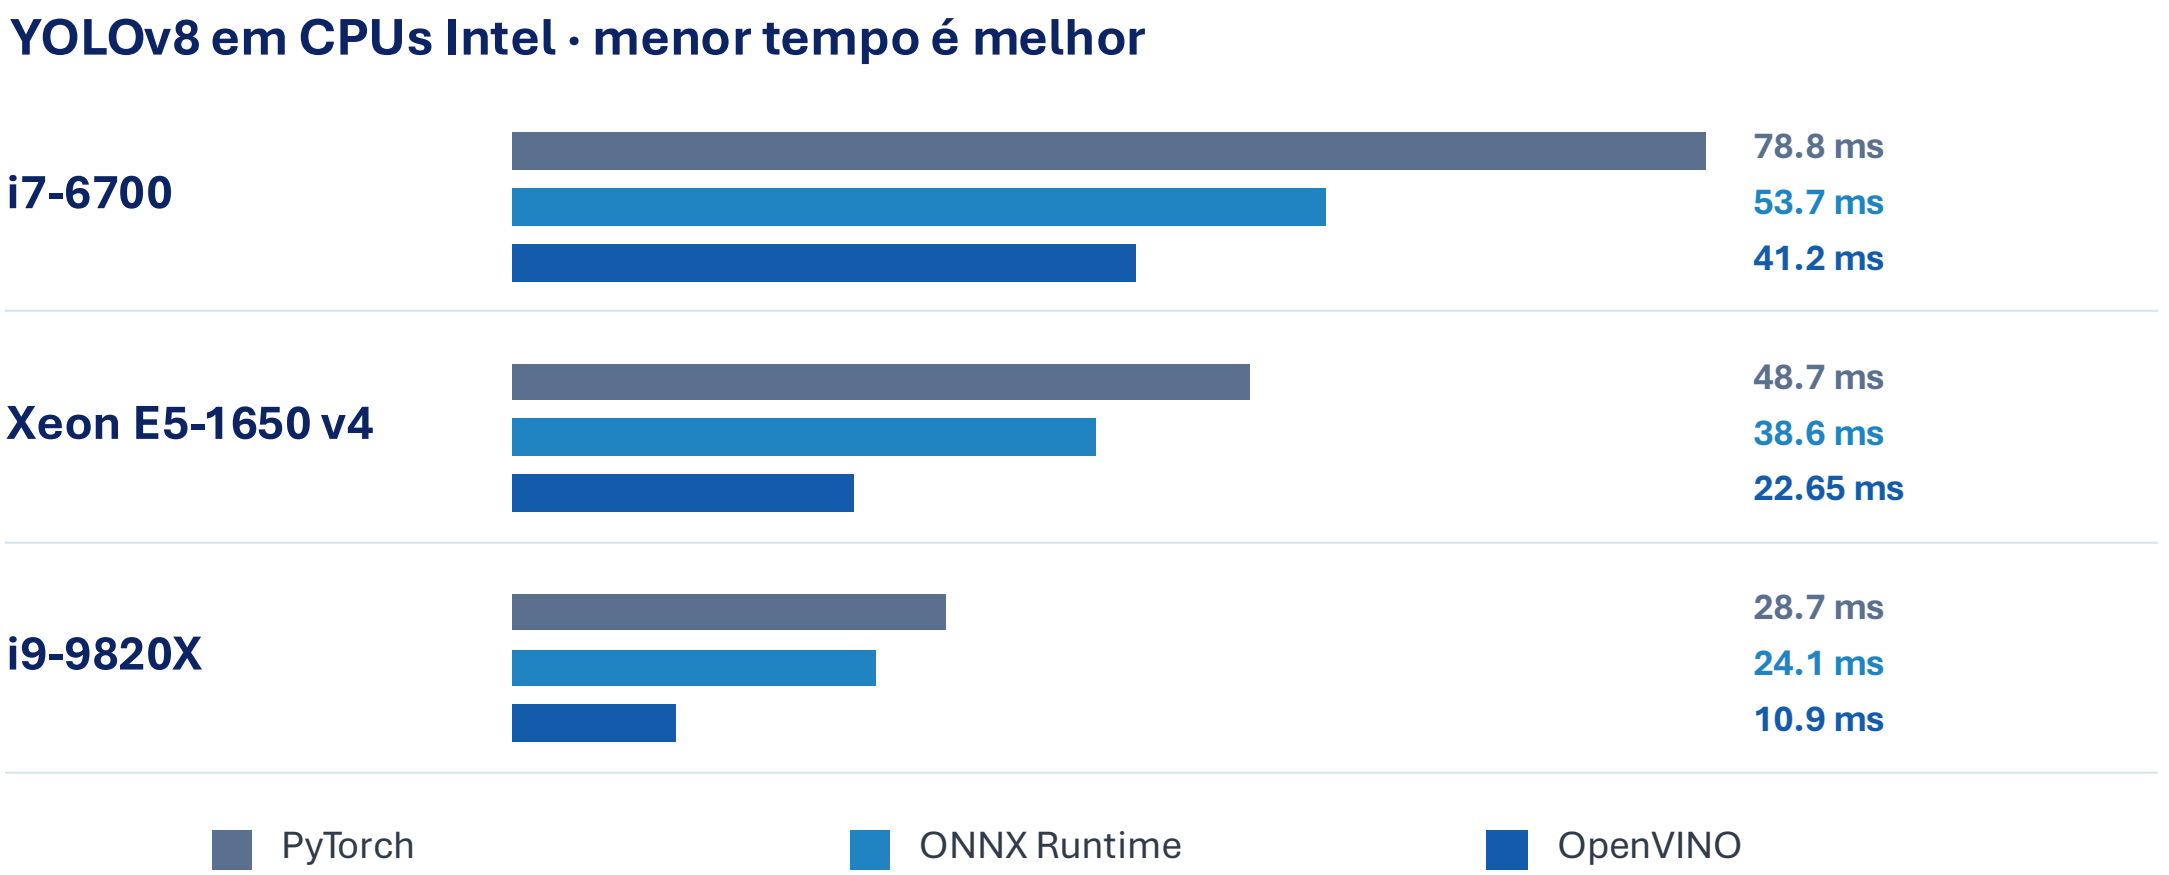

### Grounding DINO

Detecção guiada por texto

*Fonte: Fernandez et al. (2026), Figuras 1–3, p. 3. As entradas têm dimensões diferentes.*

Inatel

# ARTIGO 1 · OPENVINO NAS CPUS INTEL




*Fonte: Fernandez et al. (2026), Tabela II, p. 4. Precisão FP32 · batch 1.*

Inatel

# ARTIGO 1 · TENSORRT NAS GPUS NVIDIA

## YOLOv8 em GPU NVIDIA · TensorRT acelera CNNs

### RTX 6000

PyTorch

7.78 ms

**TensorRT**

**1.55 ms**

**5.0× mais rápido**

### RTX 2080

PyTorch

7.91 ms

**TensorRT**

**2.15 ms**

**3.7× mais rápido**

### Jetson AGX Orin

PyTorch

20.84 ms

**TensorRT**

**10.57 ms**

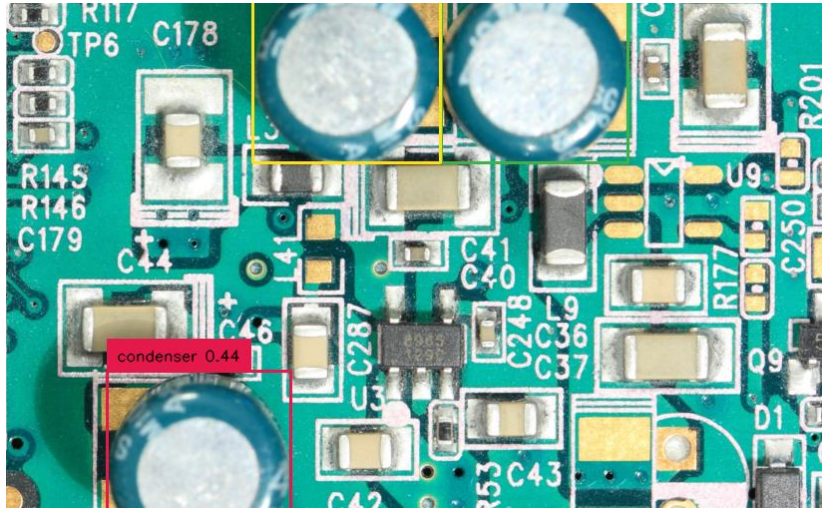
**2.0× mais rápido**

*Fonte: Fernandez et al. (2026), Tabela II, p. 4. Mesmo modelo e precisão FP32.*

Inatel

# ARTIGO 1 · TRANSFORMER MUDA O RANKING

## Grounding DINO quebra a regra das CNNs




| RTX 6000 | Jetson AGX Orin |
|---|---|
| PyTorch | PyTorch |
| **123 ms** | **1290.8 ms** |
| TensorRT | TensorRT |
| **213.2 ms** | **1082.7 ms** |
| **PyTorch vence** | **TensorRT vence** |

**O melhor runtime depende da arquitetura e da plataforma.**

*Fonte: Fernandez et al. (2026), Tabela IV, p. 6. Tempos de inferência em FP32.*

Inatel

# ARTIGO 2 · JETSON AGX ORIN

Cinco frameworks e desempenho além da latência · Ratul et al. (2025)

Inatel

# ARTIGO 2 · PROTOCOLO E MODELOS

## Jetson AGX Orin · ImageNet val2012 + modelos representativos

| | |
|---|---|
| **Modelos** | ResNet152 · MobileNetV2 · SqueezeNet · EfficientNet-B0 · VGG16 |
| **Outros** | Swin Transformer · YOLOv5s |
| **Precisão** | FP16 com otimizações do runtime |
| **Batch** | 2, 4, 8, 16, 32, 64, 128 (JAX: somente 2–8) |
| **Instrumentação** | 50 warm-ups; jtop a 10 Hz para RAM e potência |

*Fonte: Ratul et al. (2025), Seções 4.1–4.10, Tabelas 1–3.*

Inatel

# ARTIGO 2 · DIFERENTES MECANISMOS DE ACELERAÇÃO

## Frameworks da comparação e sua estratégia

| | |
|---|---|
| **PyTorch** | CUDA + cuDNN; baseline flexível |
| **ONNX Runtime** | Grafo ONNX; provider de execução em GPU |
| **TensorRT** | Fusão de camadas + tuning de kernels |
| **Apache TVM** | Compilação e autotuning para o alvo |
| **JAX** | Compilação JIT com XLA |

*Fonte: Ratul et al. (2025), Seções 3–4 e Tabela 2.*

Inatel

# ARTIGO 2 · DISTRIBUIÇÃO DOS TEMPOS MEDIDOS

**Tempo médio por amostra: um mesmo hardware, runtimes muito diferentes**

| ResNet152 | |
|---|---|
| PyTorch | 9.239 ms |
| ONNX Runtime | 285.534 ms |
| **TensorRT** | **2.282 ms** |
| TVM | 7.429 ms |
| JAX | 29.096 ms |

| YOLOv5s | |
|---|---|
| PyTorch | 2.300 ms |
| ONNX Runtime | 26.287 ms |
| **TensorRT** | **0.882 ms** |
| TVM | 4.662 ms |
| JAX | 11.686 ms |

**TensorRT foi o mais rápido nesses dois casos; resultados dependem do stack.**

*Fonte: Ratul et al. (2025), Tabela 6, p. 11. Jetson AGX Orin · FP16.*

Inatel

# ARTIGO 2 · TENSORRT REDUZ A LATÊNCIA

**Jetson AGX Orin · tempo médio por amostra (ms)**

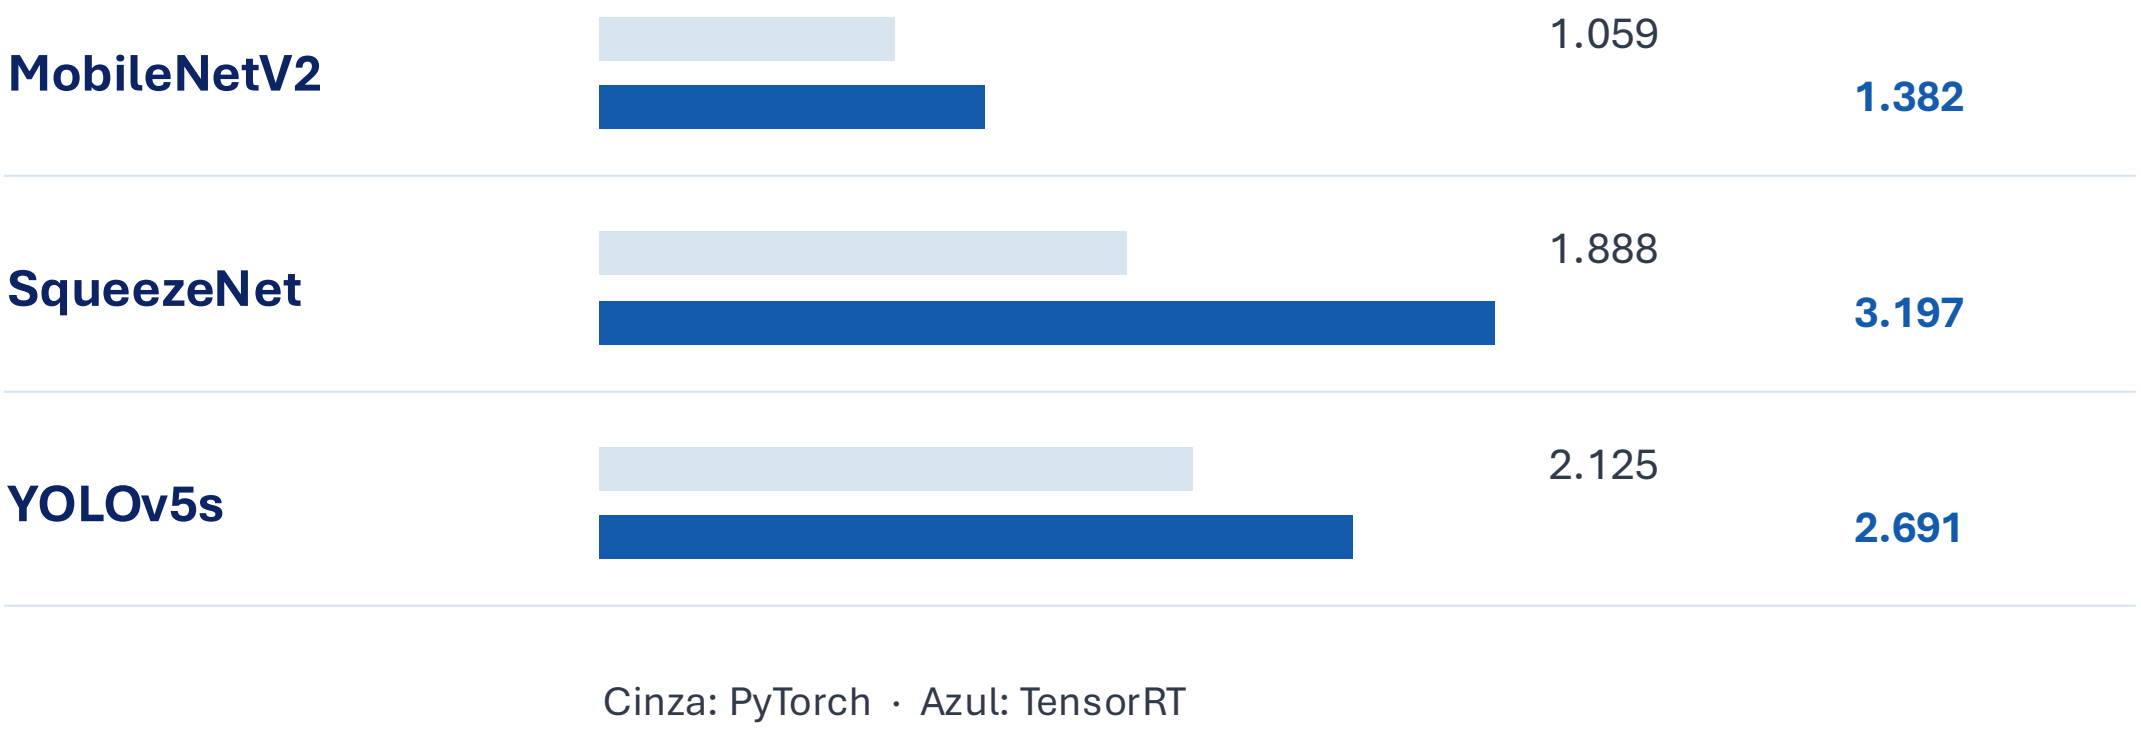
| ResNet152 | MobileNetV2 | YOLOv5s |
|---|---|---|
| PyTorch | PyTorch | PyTorch |
| 9.239 | 4.201 | 2.300 |
| TensorRT | TensorRT | TensorRT |
| 2.282 | 1.136 | 0.882 |
| 4.0× mais rápido | 3.7× mais rápido | 2.6× mais rápido |

*Fonte: Ratul et al. (2025), Tabela 6, p. 11. FP16. ONNX Runtime foi mais lento nesse stack.*

Inatel

# ARTIGO 2 · THROUGHPUT E TAMANHO DE BATCH

**Throughput máximo com batches variáveis · amostras/s**



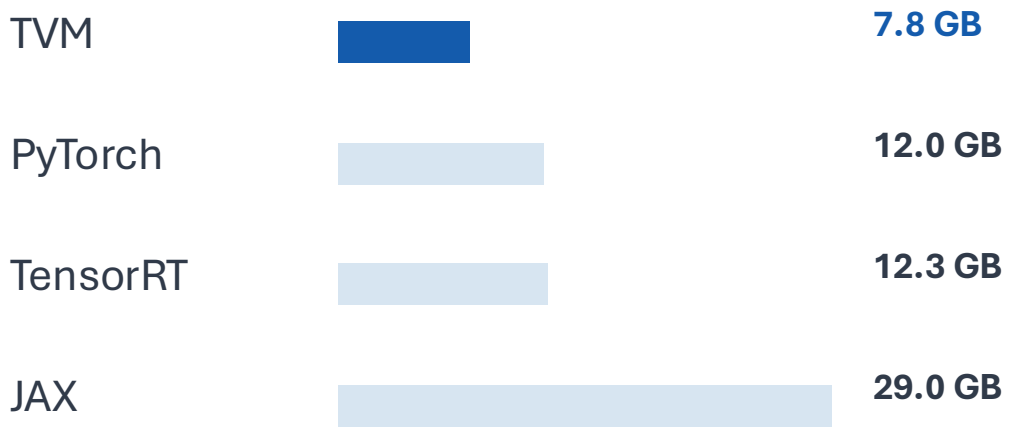

*Fonte: Ratul et al. (2025), Tabela 7, p. 13. Máximos em diferentes tamanhos de lote.*

Inatel

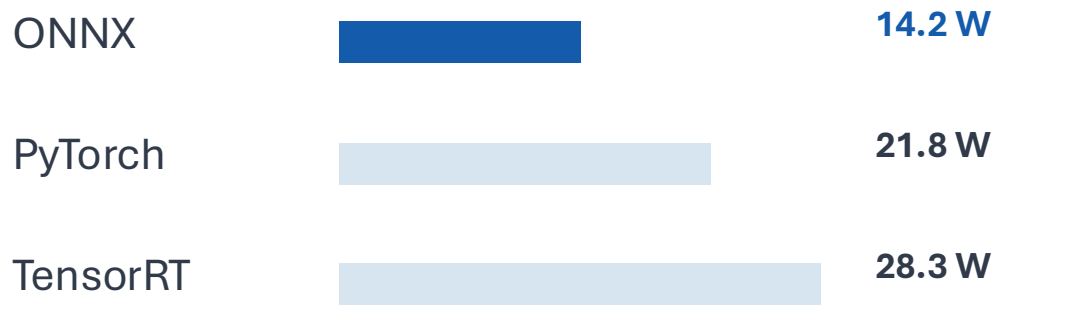
# ARTIGO 2 · MEMÓRIA E POTÊNCIA

**ResNet152 · custo em memória e potência na mesma plataforma**

## MEMÓRIA DE SISTEMA




## POTÊNCIA MÉDIA




**Baixa potência em W não garante baixa energia por inferência.**

*Fonte: Ratul et al. (2025), Tabelas 8–9, pp. 14–15. Médias reportadas.*

Inatel

# ARTIGO 3 · ENERGIA E TEMPO REAL

YOLOv8l e RT-DETR-l em plataformas edge · Suchý & Turčaník (2026)

Inatel

# ARTIGO 3 · O QUE SIGNIFICA TEMPO REAL?

## Pipeline completo no vídeo MOT16-13

**Decodificação** → **Pré-processamento** → **Inferência** → **Pós-processamento** → **FPS + energia**

## Alvo explícito do artigo

**≥ 25 FPS**

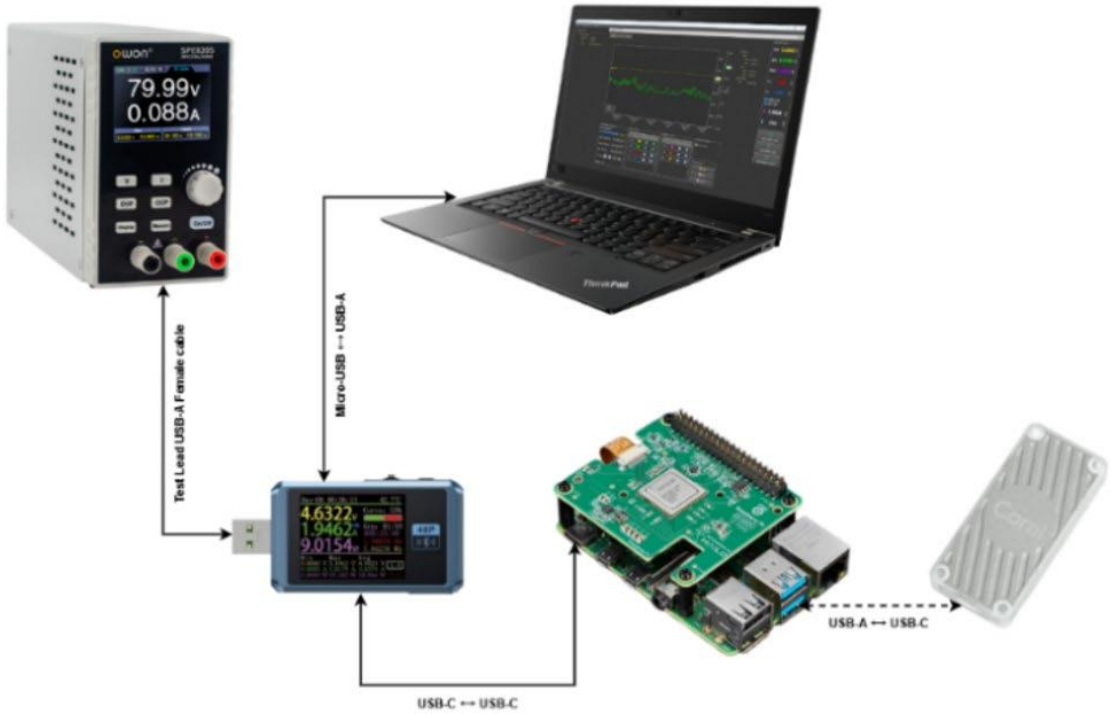
até 40 ms por frame, em média

*Fonte: Suchý & Turčaník (2026), Seção Experimental pipeline, p. 5.*

Inatel

# ARTIGO 3 · PLATAFORMAS E ACELERADORES

## Duas plataformas com caminhos de execução distintos




### Raspberry Pi 5

8 GB · CPU ARM
Coral Edge TPU / Hailo-8

### Jetson Orin NX

16 GB · GPU NVIDIA
TensorRT FP32 / INT8

*Fonte: Suchý & Turčaník (2026), Figura 1 e metodologia, pp. 4–5.*

Inatel

# ARTIGO 3 · RASPBERRY PI 5 E NPU

## YOLOv8l · Raspberry Pi 5 com e sem NPU




**A NPU melhora o desempenho, mas ainda não chega a 25 FPS.**

*Fonte: Suchý & Turčaník (2026), Tabela 4, p. 6. Edge TPU usa resolução 224×224.*

Inatel

# ARTIGO 3 · JETSON ORIN NX E TENSORRT

**Melhor execução de cada detector no TensorRT INT8**

## YOLOv8l

**15.94**

FPS do pipeline

**0.996 FPS/W · 16 W**

## RT-DETR-l

**18.01**

FPS do pipeline

**1.060 FPS/W · 17 W**

**Meta do artigo: 25 FPS — nenhuma configuração alcançou.**

*Fonte: Suchý & Turčaník (2026), Tabelas 6–7, pp. 7–8. Vídeo completo.*

Inatel

# ARTIGO 3 · ACURÁCIA APÓS A EXPORTAÇÃO

**Acurácia após exportação e quantização · COCO val2017**

## YOLOv8l

PyTorch

**0.530**

**TensorRT INT8**

**0.509** **-0.021 mAP**

## RT-DETR-l

PyTorch

**0.524**

**TensorRT INT8**

**0.492** **-0.032 mAP**

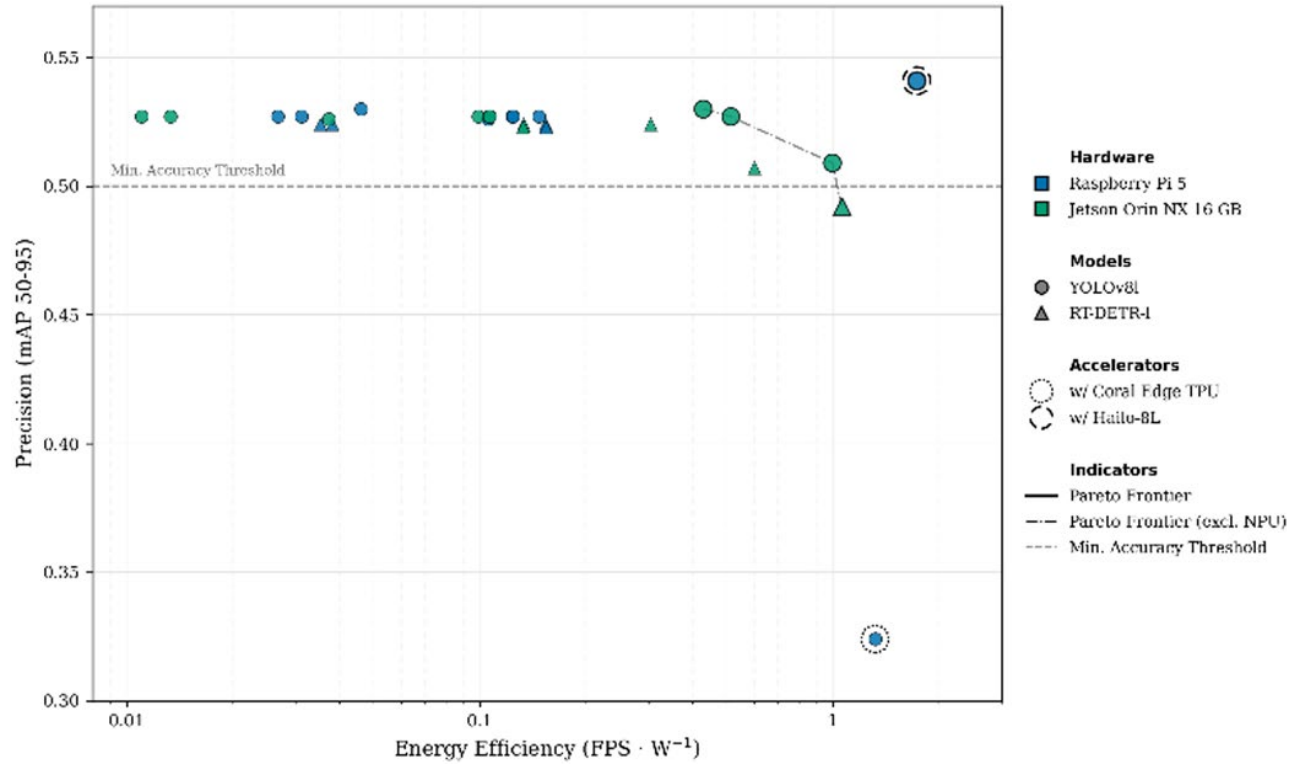
**Conversão e INT8 exigem validação da precisão, não só do FPS.**

*Fonte: Suchý & Turčaník (2026), Tabelas 2–3, pp. 5–6. Edge TPU em 224×224: mAP 0,324.*

Inatel

# ARTIGO 3 · FRONTEIRA DE PARETO

## Pareto: pontos que equilibram mAP e FPS/W




*Fonte: Suchý & Turčaník (2026), Figura 10, p. 9. Critério ilustrativo mAP ≥ 0,50.*

### Como ler

→ Direita: maior FPS/W
→ Acima: maior mAP
→ Fronteira: opções não dominadas

Inatel

# COMPARAÇÃO DOS TRÊS ESTUDOS

**Resultados complementares, não um ranking universal**

## 01 · INDUSTRIAL

Hardware

**CPU + GPU desktop**

Protocolo

FP32 · batch 1

**Latência do modelo**

## 02 · JETSON AGX

Hardware

**Jetson AGX Orin**

Protocolo

FP16 · batches variados

**Latência · RAM · W**

## 03 · DETECÇÃO

Hardware

**Pi 5 + Jetson Orin NX**

Protocolo

FP32 / INT8 · vídeo

**mAP · FPS · FPS/W**

> **Comparar somente números de ms ou FPS entre artigos seria incorreto.**

*Fontes: os três trabalhos fornecidos; síntese de seus protocolos experimentais.*

Inatel

# POR QUE O RANKING PODE MUDAR?

## Quatro causas que explicam resultados aparentemente contraditórios

| | |
|---|---|
| **1 · Arquitetura** | CNN × Transformer, operadores e grafos dinâmicos. |
| **2 · Hardware** | Intel CPU × NVIDIA GPU × ARM CPU × NPU. |
| **3 · Runtime** | Providers, compilador, fusão de operadores e kernel tuning. |
| **4 · Protocolo** | FP32/FP16/INT8, batch, pre/pós e objetivos de energia. |

*Síntese interpretativa baseada nos três artigos.*

Inatel

# COMO ESCOLHER UM RUNTIME NA PRÁTICA?

## Procedimento orientado por evidências

- 1. Definir a meta: tempo por frame, FPS sustentado, mAP e potência.
- 2. Fixar modelo, entrada, batch e qualidade aceitável.
- 3. Verificar compatibilidade e exportação dos operadores.
- 4. Testar runtimes no hardware de destino com warm-up.
- 5. Medir pipeline completo, memória, energia e regressão de mAP.

*Recomendação prática derivada da comparação, não um experimento adicional dos artigos.*

Inatel

# LIMITAÇÕES PARA INTERPRETAR OS BENCHMARKS

## Resultados dependem das condições experimentais

- As entradas, resoluções e métricas variam entre os estudos.
- As versões de frameworks e seus providers afetam comparações.
- Nem toda arquitetura exporta ou executa em todas as NPUs.
- Acurácia pode cair após conversão; menor W pode significar execução lenta.
- Não há validação universal para outros modelos, hardwares ou cenários.

*Síntese crítica dos protocolos e limitações relatados nos três artigos.*

Inatel

# CONCLUSÕES

**Não existe runtime vencedor em qualquer cenário**

| | | |
|---|---|---|
| **01** | **FRAMEWORK** | Pode acelerar muito; depende dos operadores e do export. |
| **02** | **HARDWARE** | Define quais otimizações podem ser exploradas. |
| **03** | **PIPELINE** | É onde a precisão, o FPS e a potência devem ser validados. |

> **Benchmark no hardware real, usando dados e metas do seu sistema.**

Inatel

# REFERÊNCIAS PRINCIPAIS

## Trabalhos analisados


1. FERNANDEZ, M. G. et al. Benchmarking Edge Inference Strategies for Deep Learning Models in Industrial Machine Vision. arXiv:2607.11356v1, 2026.

2. RATUL, I. J.; ZHOU, Y.; YANG, K. Accelerating Deep Learning Inference: A Comparative Analysis of Modern Acceleration Frameworks. Electronics, 14(15), 2977, 2025. DOI: 10.3390/electronics14152977.

3. SUCHÝ, I.; TURČANÍK, M. Review of large YOLOv8 and RT-DETR energy efficiency on edge devices for real-time detection. Scientific Reports, 16, 10908, 2026. DOI: 10.1038/s41598-026-46453-6.


*Referências consultadas nos três PDFs fornecidos para o seminário.*

Inatel




# OBRIGADO!

Perguntas?

Seminário de Mestrado · Inferência de IA na Borda

inatel.tecnologias
inatel.tecnologias
inateloficial
company/inatel
www.inatel.br

**Campus em Santa Rita do Sapucaí**
**Minas Gerais - Brasil**
Av. João de Camargo, 510
Centro - 37536-001

**Inatel**

_o futuro
não tem hora,
mas tem lugar.



https://forms.gle/rqihyB77diSqyGoKA



https://github.com/Mestrado-Alvaro-Ribeiro/alvaro-ribeiro-985-tp558/tree/main/seminar5

Inatel